UNIVERSIDAD DON BOSCO

DATAWAREHOUSE Y MINERÍA DE DATOS



“ANÁLISIS DEL PROCESO DE COMERCIO ELECTRÓNICO EN OLIST”

FASE I & FASE II

PRESENTADO POR:

Apellidos	Nombres	Carnet
ACOSTA DURÁN	DOUGLAS ELISEO	AD250284
AGUILAR VANEGAS	LUIS EDUARDO	AV250234
ALVARADO MURILLO	FERNANDO JOSÉ	AM250225
PINEDA ANAYA	GUADALUPE DEL CARMEN	PA250208

CATEDRATICO:

ING. BLADIMIR DÍAS CAMPOS

Nota: por el peso del proyecto este se ha alojado en github

URL: https://github.com/EAcosta10/DMD104_G01T_2026

SOYAPANGO, SAN SALVADOR ESTE, 14 DE SEPTIEMBRE DE 2026

ÍNDICE

I. FASE 1 1

II. DESCRIPCIÓN DE LA ORGANIZACIÓN 1

III. FUENTES DE INFORMACIÓN 1

IV. ENFOQUE DE ANÁLISIS 2

V. DISEÑO DEL MODELO DIMENCIONAL (ESQUEMA EN ESTRELLA) 2

VI. PREPARACION DE LOS DATOS PARA EL ANÁLISIS (Fase KDD) 3

VII. PROCESO ETL 4

VIII. FASE 2 10

IX. CUBO OLAP DE OLIST 10

X. PROYECTO DE MINERÍA DE DATOS (KDD) – ANÁLISIS INTEGRAL DE OLIST 14

1. Preparación y Selección de Datos 14

2. Modelado de Minería de Datos (KDD fase 4) 20

3. Interpretación y Evaluación (KDD Fase 5) 24

XI. BIBLIOGRAFÍA 38

I. FASE 1

II. DESCRIPCIÓN DE LA ORGANIZACIÓN

Olist es una plataforma de *Marketplace* y tecnología ubicada en Brasil, donde conecta a pequeños y medianos comerciantes directamente con los principales canales de comercio electrónico, simplificando la venta en línea para los pequeños negocios al encargase de la gestión de inventario en el catalogo, el procesamiento de ordenes, el cobro, y la coordinación de logística de cada envío.

3.1 Problema que buscamos resolver

Con el comercio de las ventas, han surgido algunos obstáculos que afectan tanto la ganancia como la experiencia del usuario:

- **Retrasos logísticos:** Los tiempos de entrega varían mucho según la zona, lo que genera insatisfacción y malas reseñas.
- **Falta de lealtad del cliente:** Muchos compradores solo realizan una compra y no vuelven, por lo que necesitamos entender mejor sus hábitos.
- **Desempeño de los vendedores:** No existe una forma clara de evaluar quiénes cumplen mejor con los pedidos o generan más ingresos.

III. FUENTES DE INFORMACIÓN

Utilizaremos los datos públicos de Olist disponibles en Kaggle. Esta información está organizada en archivos CSV que cubren diferentes aspectos del negocio:

- olist_orders_dataset.csv: Registro del ciclo de vida del pedido (estado, marcas de tiempo de compra, despacho y entrega).
- olist_order_items_dataset.csv: Detalle por línea de producto (precios, flete, relación vendedor-producto).
- olist_order_payments_dataset.csv: Transacciones financieras y métodos de pago.
- olist_order_reviews_dataset.csv: Calificaciones y comentarios de los compradores.
- olist_customers_dataset.csv: Información geográfica del cliente.
- olist_sellers_dataset.csv: Datos geográficos de los vendedores aliados.
- olist_products_dataset.csv: Atributos físicos y categorías de los productos.

product_category_name_translation.csv: Traducción de categorías de portugués a inglés.

IV. ENFOQUE DE ANÁLISIS

Nos enfocaremos principalmente en la **Logística y el Cumplimiento de Ventas**. Analizaremos todo el recorrido, desde que se hace el pedido hasta que el cliente deja su opinión:

- **Procesamiento:** Cómo se registra la orden y el pago.
- **Preparación:** El tiempo que le toma al vendedor enviar el paquete.
- **Entrega:** El tiempo real de viaje frente a la fecha prometida.
- **Opinión del cliente:** El nivel de satisfacción final.

V. DISEÑO DEL MODELO DIMENCIONAL (ESQUEMA EN ESTRELLA)

Para que los datos sean útiles, hemos creado un diseño organizado que separa los hechos de las características descriptivas.

1.1 Tabla de Hechos:

- **Fact_Ventas_y_Logistica:** Almacena la granularidad por línea de detalle de orden. Contiene las llaves foráneas y métricas calculadas como: *Precio_Producto*, *Valor_Flete*, *Monto_Total_Linea*, *Dias_Despacho_Vendedor*, *Dias_Total_Entrega* y el indicador *Es_Entrega_Tardia*.

1.2 Tablas de Dimensiones:

- **Dim_Cliente:** Identificador único, ciudad y estado del comprador.
- **Dim_Vendedor:** Identificador, ciudad y estado del comerciante.
- **Dim_Producto:** Categoría y dimensiones volumétricas del artículo.
- **Dim_Tiempo:** Dimensión conformada con jerarquías de fecha (Año, Mes, Día) extraída de las marcas de tiempo de los pedidos.

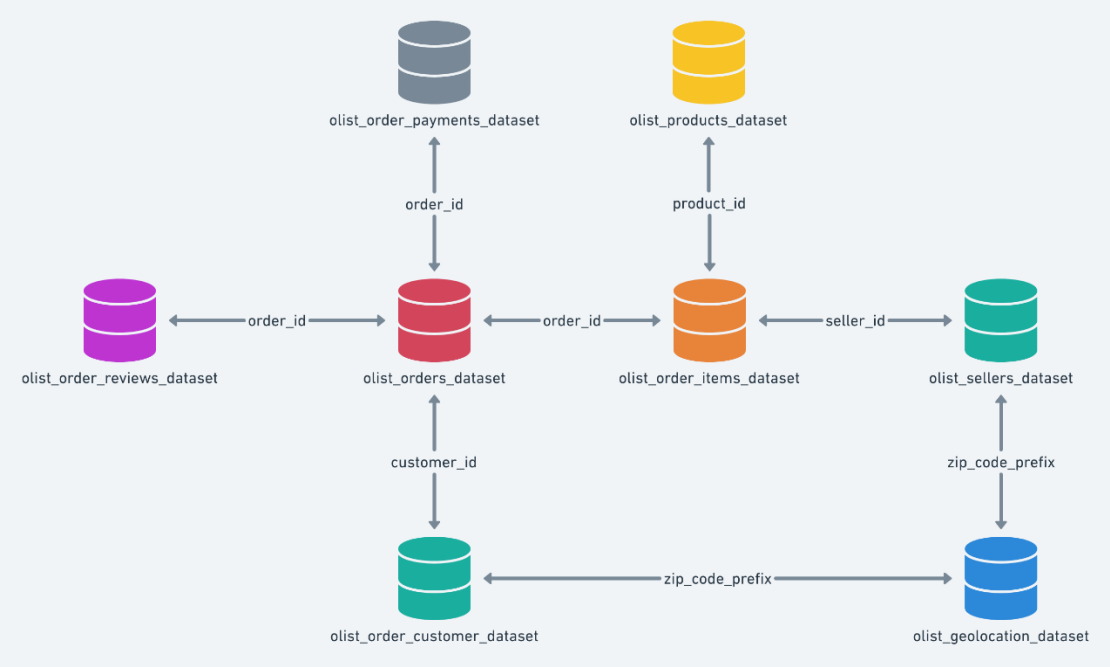


Figura 1: esquema en estrella del modelo dimensional (Fuente: Olist, 2026)

VI. PREPARACION DE LOS DATOS PARA EL ANÁLISIS (Fase KDD)

¿Por qué un nuevo entorno analítico?

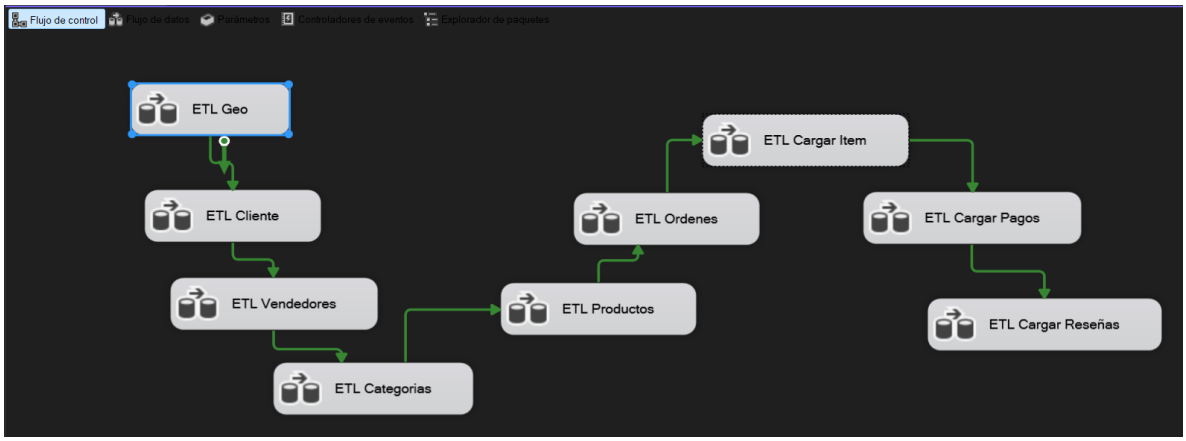
Para trabajar de forma segura y eficiente, crearemos una base de datos independiente de la original. Esto nos permite limpiar la información, realizar cálculos complejos y aplicar modelos de minería de datos sin riesgos, asegurando que los resultados sean confiables.

Pasos del proceso:

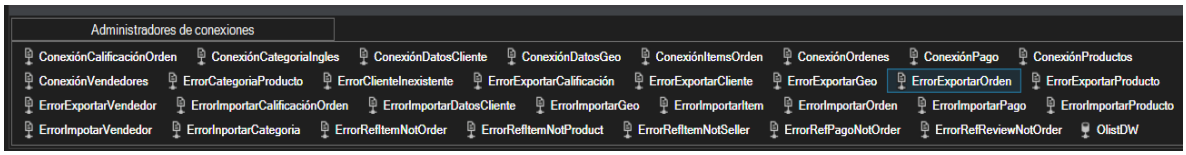
1. **Selección:** Elegimos solo los datos de los archivos CSV que son realmente importantes para la logística.
2. **Limpieza:** Corregimos errores, completamos valores faltantes y organizamos los formatos de fecha.
3. **Transformación :** Creamos nuevas medidas que no estaban en los datos originales, como el cálculo exacto de días de entrega.
4. **Carga a SQL Server:** Finalmente, guardamos todo en una base de datos profesional y lista para ser explorada.

VII. PROCESO ETL

Estructura principal segmentada por tablas



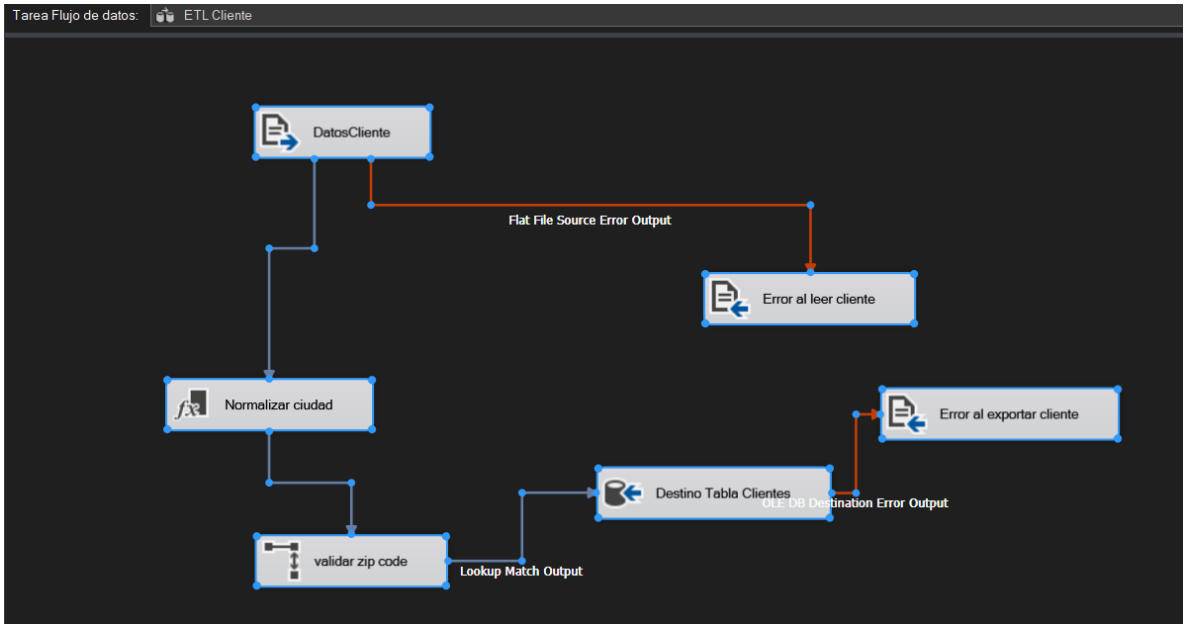
Administrador de conexiones



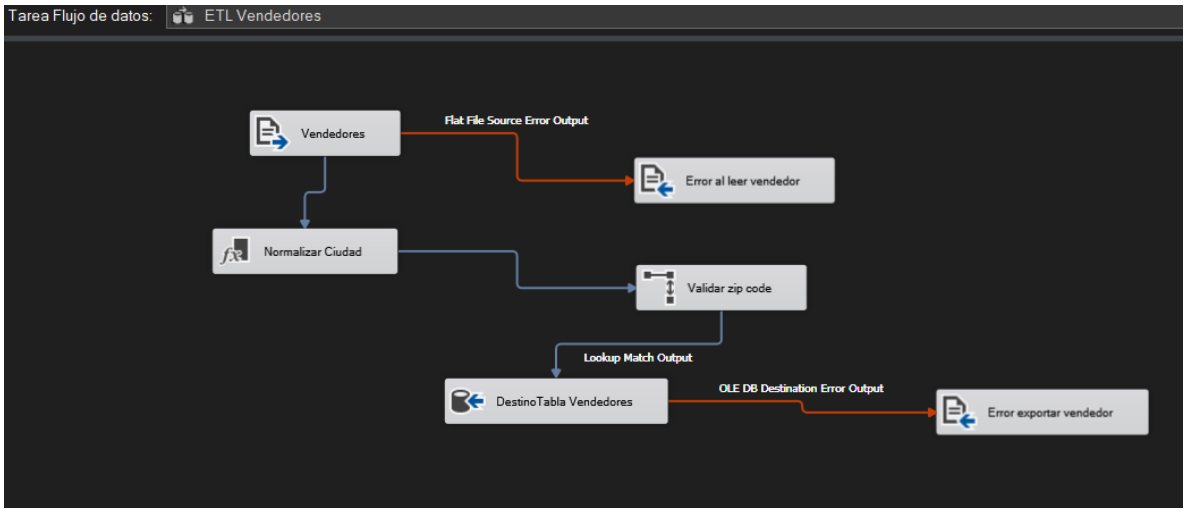
Análisis de datos de geolocalización



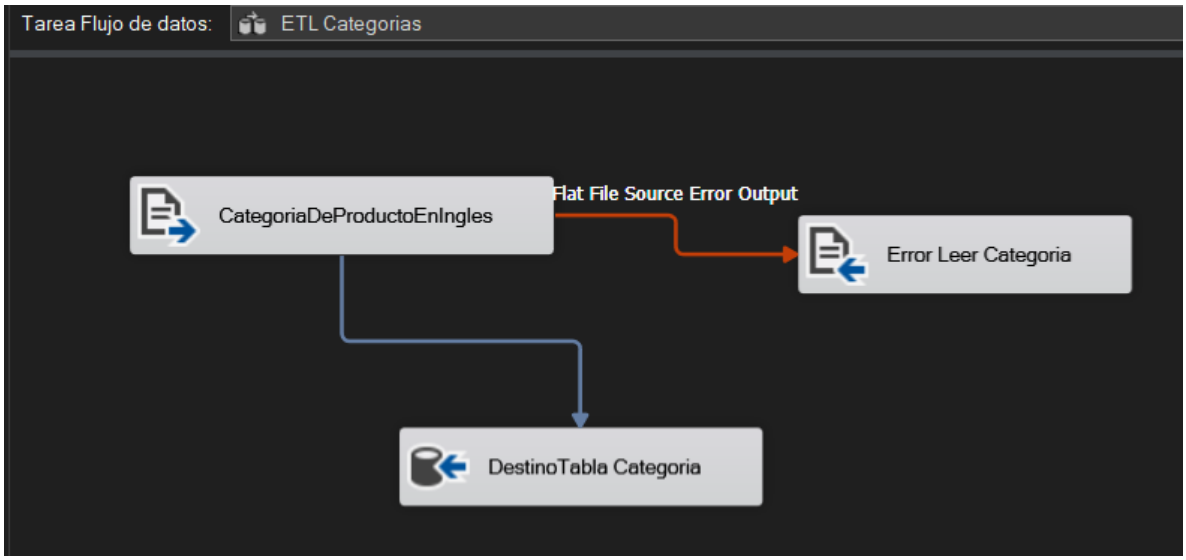
Análisis de datos de clientes



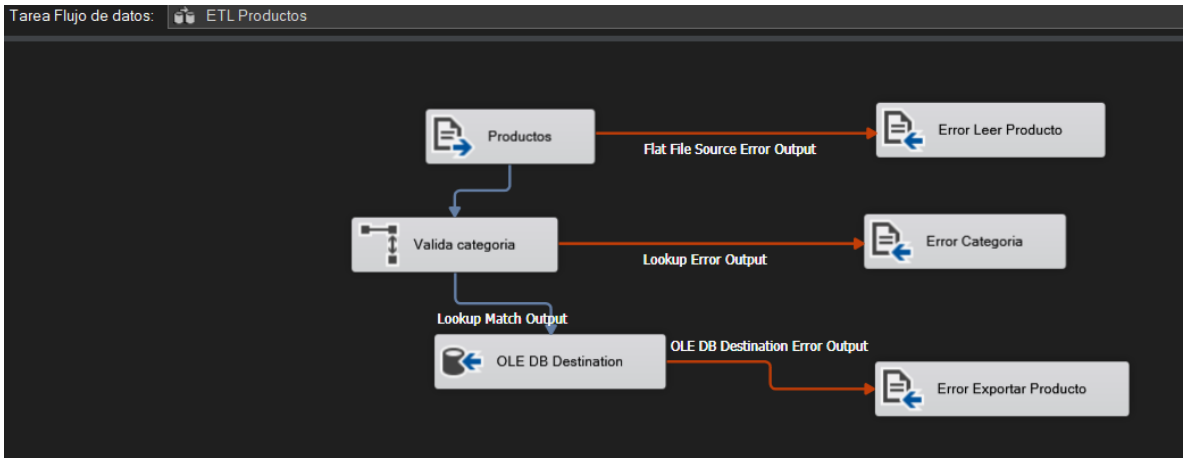
Análisis de datos de vendedores



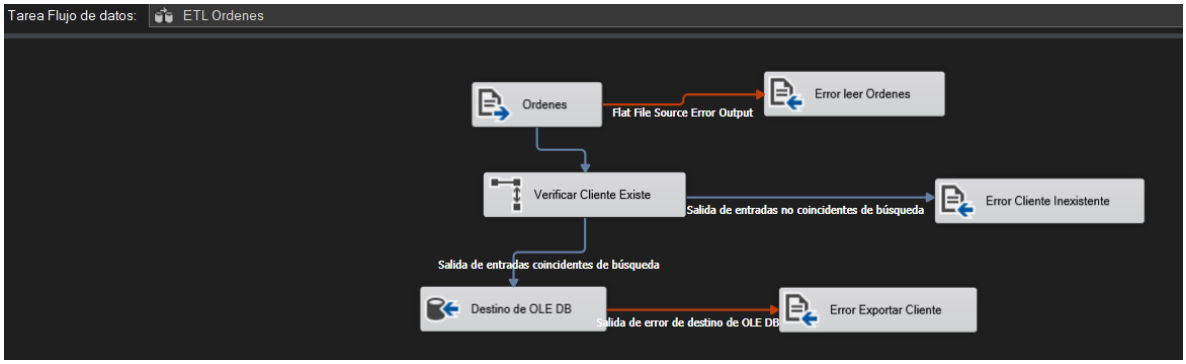
Análisis de datos de categorías



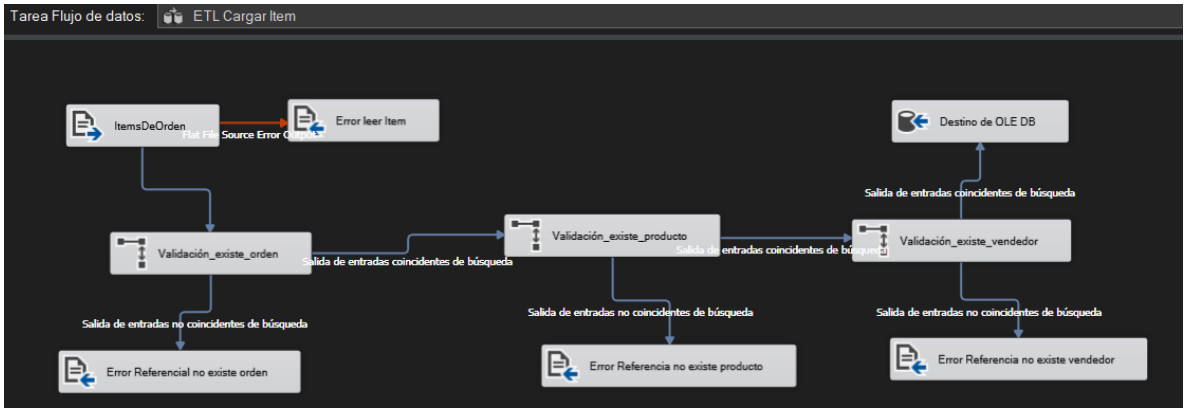
Análisis de datos de productos



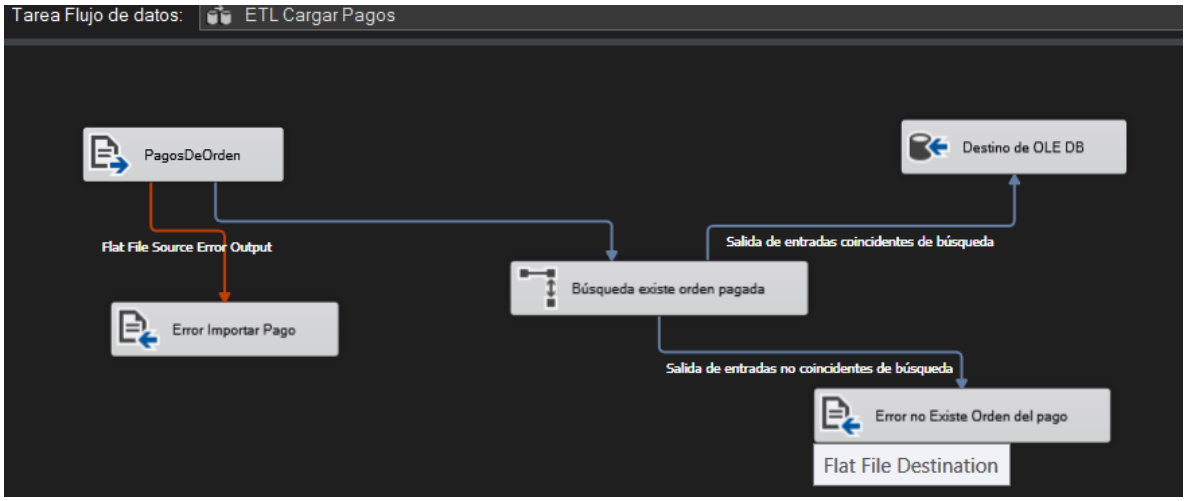
Análisis de datos de ordenes



Análisis de datos de item



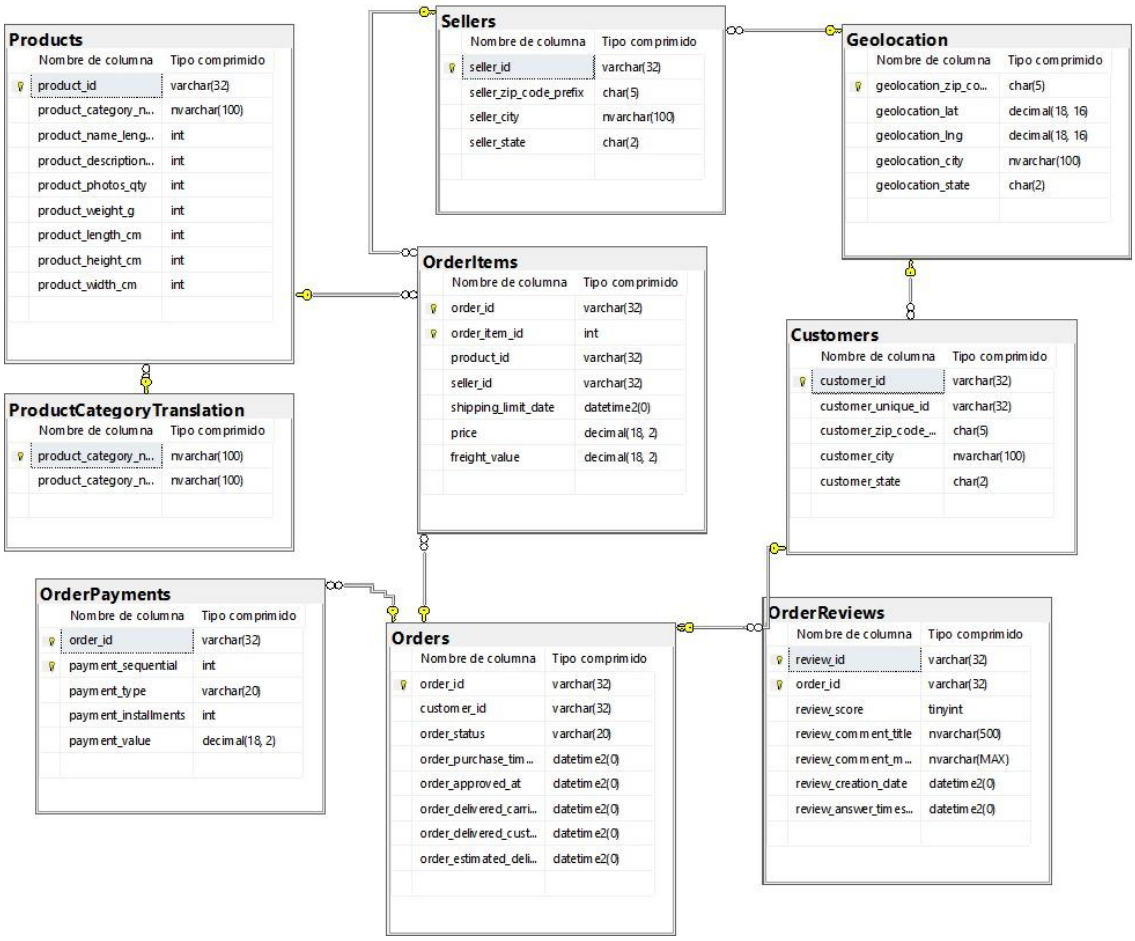
Análisis de datos de pagos



Análisis de datos de reseñas



Estructura de la base de datos destino

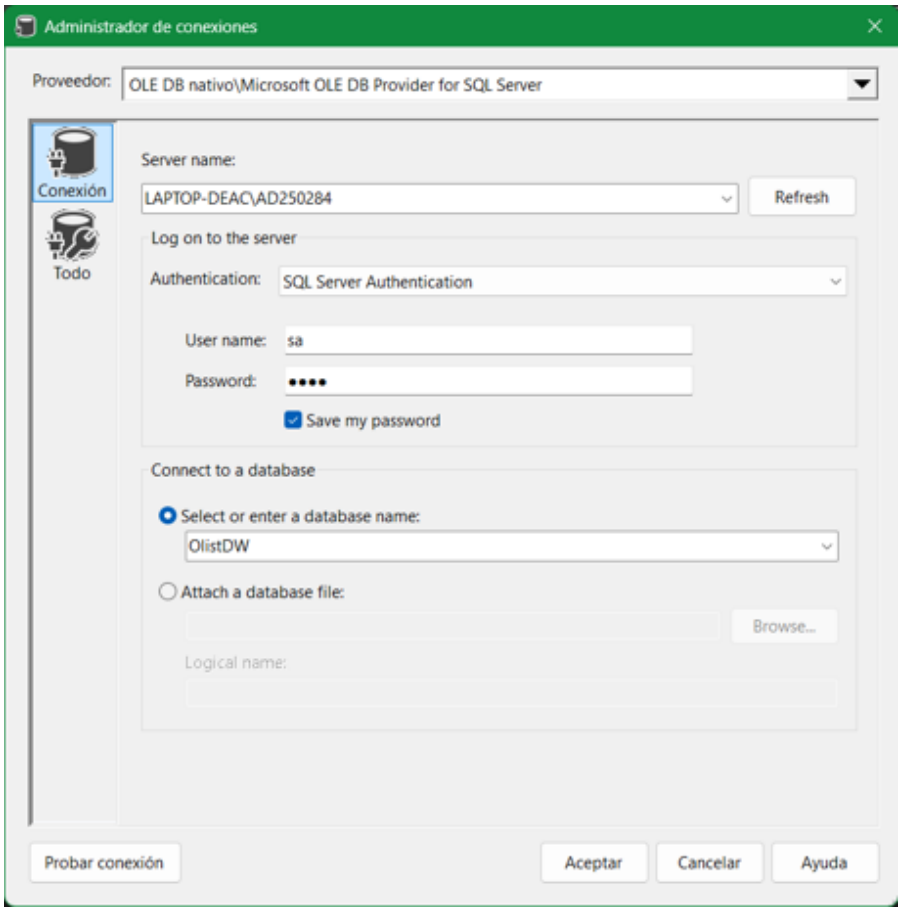


VIII. FASE 2

IX. CUBO OLAP DE OLIST

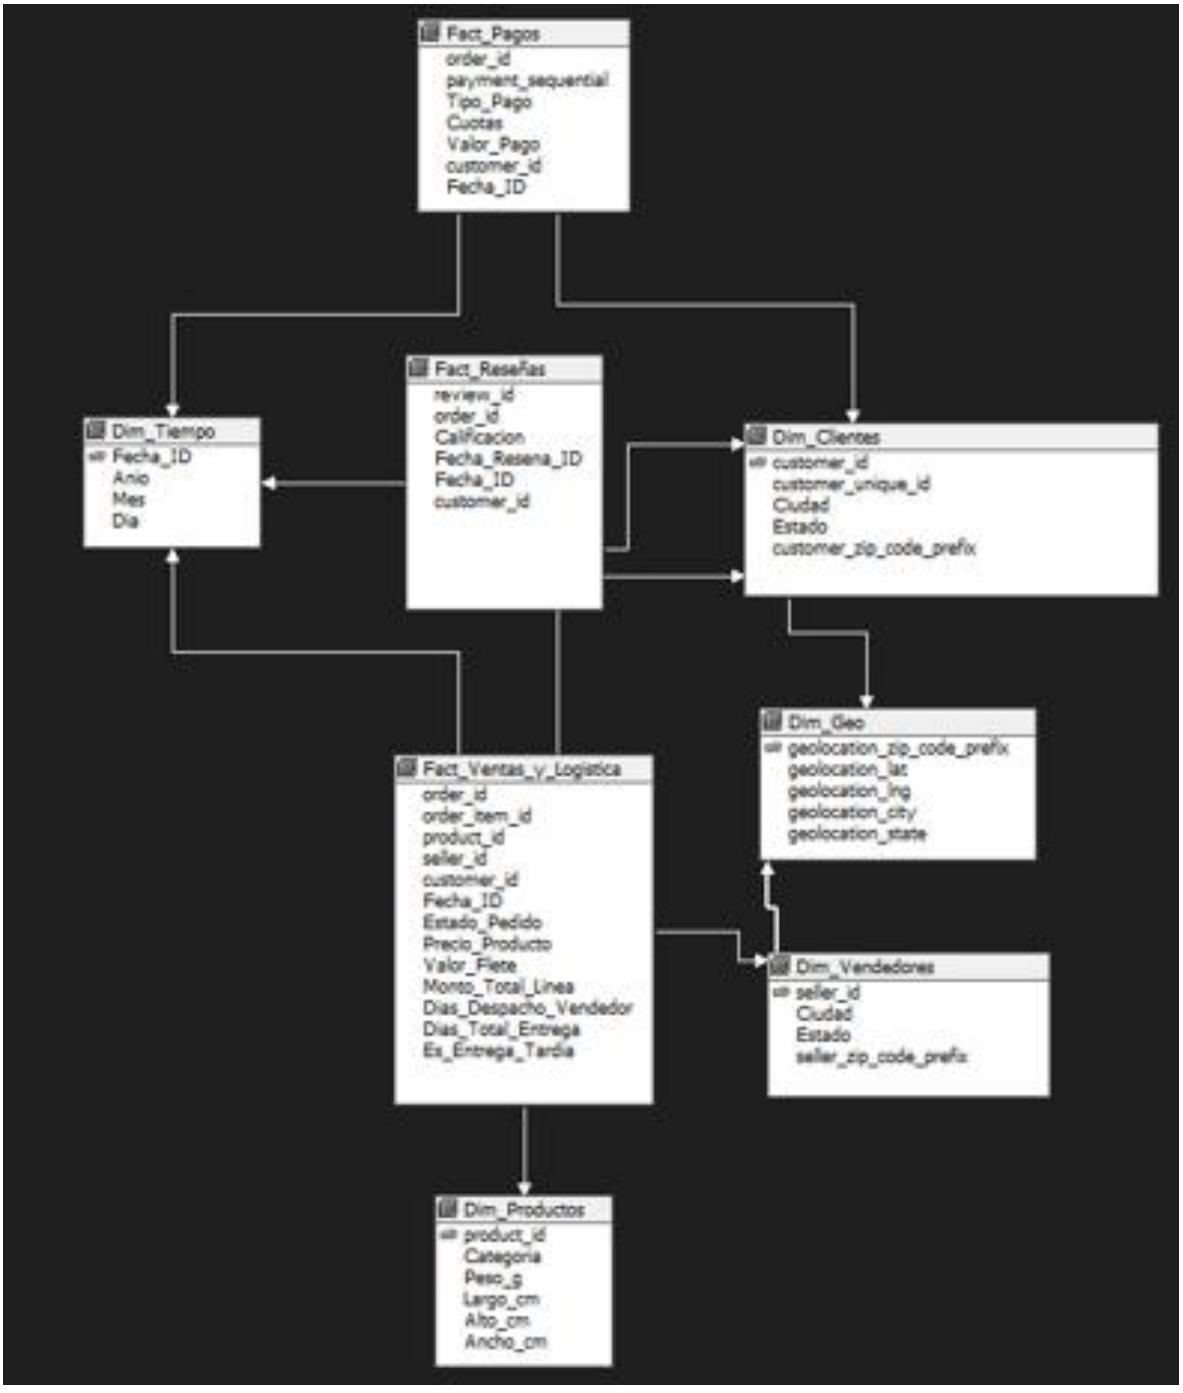
1.1. Configuración de conexión

Se procedió a conectar el proyecto del cubo olap directamente a la base de datos de salida del ETL.



1.2 Configuración del cubo OLAP

Para trascender el análisis predictivo y dotar a los tomadores de decisiones de una herramienta de exploración multidimensional, se diseñó e implementó un modelo de Business Intelligence basado en un **Esquema de Constelación**. A diferencia de un diseño tradicional, esta arquitectura integra múltiples procesos de negocio (Logística, Finanzas y Satisfacción del Cliente) centralizados en tres Tablas de Hechos que interactúan mediante Dimensiones Conformadas (compartidas).



Este modelo se alimenta de vistas SQL optimizadas, transformando datos transaccionales crudos en métricas calculadas y jerarquías analíticas listas para su explotación.

1.3 Tablas de Hechos (Fact Tables)

El corazón numérico del modelo está fragmentado estratégicamente en tres áreas de impacto operativo:

a. **Fact_Ventas_y_Logistica (Operación y Despacho):**

- **Granularidad:** Nivel de ítem por orden (order_item_id).
- **Métricas Físicas y Financieras:** Precio del producto (Precio_Producto), costo de envío (Valor_Flete) y el cálculo consolidado del Monto_Total_Linea.
- **Métricas de Eficiencia (Transformaciones ETL):** Mediante funciones lógicas temporales (DATEDIFF), el cubo pre-calcula métricas de rendimiento logístico críticas: los días que tarda el vendedor en despachar (Dias_Despacho_Vendedor) y el tiempo total de entrega (Dias_Total_Entrega). Además, integra una bandera binaria (Es_Entrega_Tardia calculada con CASE WHEN) que facilita el conteo automático de fallas operativas.

b. **Fact_Pagos (Finanzas):**

- **Granularidad:** Método de pago y cuotas aplicadas por orden.
- **Métricas:** Total pagado (Valor_Pago), número de cuotas (Cuotas) y categorización transaccional (Tipo_Pago).

c. **Fact_Reseñas (Satisfacción del Cliente):**

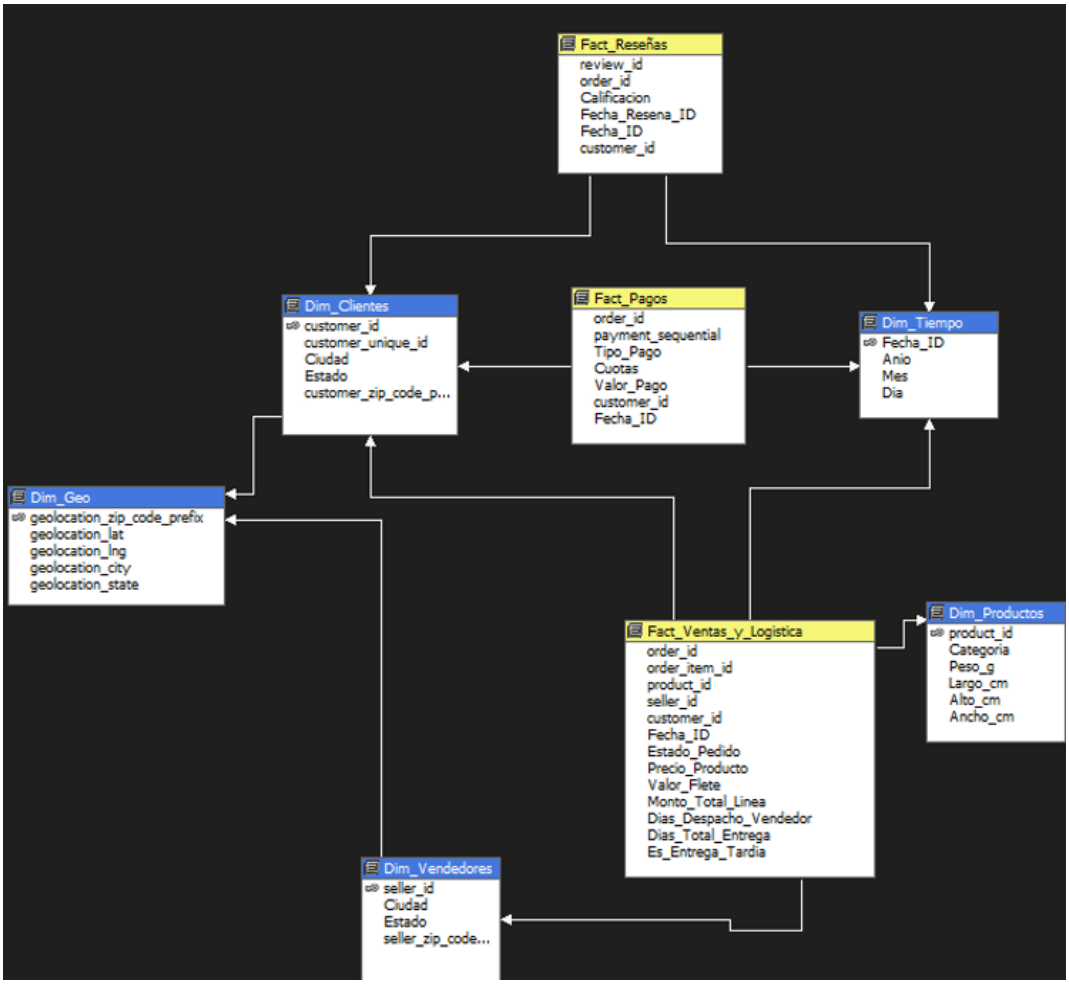
- **Granularidad:** Evaluaciones emitidas por pedido.
- **Métricas:** Puntuación otorgada por el cliente (Calificacion).

1.4 Dimensiones (Ejes Analíticos)

Para dotar de contexto a las tablas de hechos, se construyeron 5 dimensiones estructuradas para permitir la navegación *Drill-down* (de lo general a lo específico):

- **Dim_Tiempo:** Derivada de la fecha de compra (order_purchase_timestamp), extrae automáticamente jerarquías consolidadas de análisis: Anio ➔ Mes ➔ Dia.
- **Dim_Productos:** Integra la traducción de categorías al inglés (manejando valores huérfanos con ISNULL a 'Unknown Category') e incluye las dimensiones físicas del paquete (Peso_g, Largo_cm, Alto_cm, Ancho_cm).
- **Dim_Clientes y Dim_Vendedores:** Aislan la información transaccional de los actores involucrados, catalogándolos por jerarquía geográfica: Estado ➔ Ciudad ➔ zip_code_prefix.
- **Dim_Geo:** Dimensión topológica pura que almacena coordenadas exactas

(geolocation_lat, geolocation_lng) para permitir el mapeo espacial de la operación logística.



1.5 Valor Estratégico del Modelo

La verdadera ventaja competitiva de este diseño en Constelación es que permite a los gerentes de Olist cruzar mundos de datos que normalmente operan aislados. Al estar conectadas a dimensiones comunes como Dim_Tiempo o Dim_Clientes, la herramienta OLAP permite responder preguntas complejas de forma visual e instantánea, tales como:

- ¿Cómo impactan los retrasos de entrega (Es_Entrega_Tardia de Logística) en la calificación final del cliente (Calificacion de Reseñas) durante los meses de mayor demanda (Dimensiones Tiempo y Producto)?
- ¿Qué métodos de financiamiento (Tipo_Pago y Cuotas de Pagos) son más frecuentes cuando se compran productos pesados (Peso_g de Logística/Productos) en regiones específicas (Estado de Clientes)?

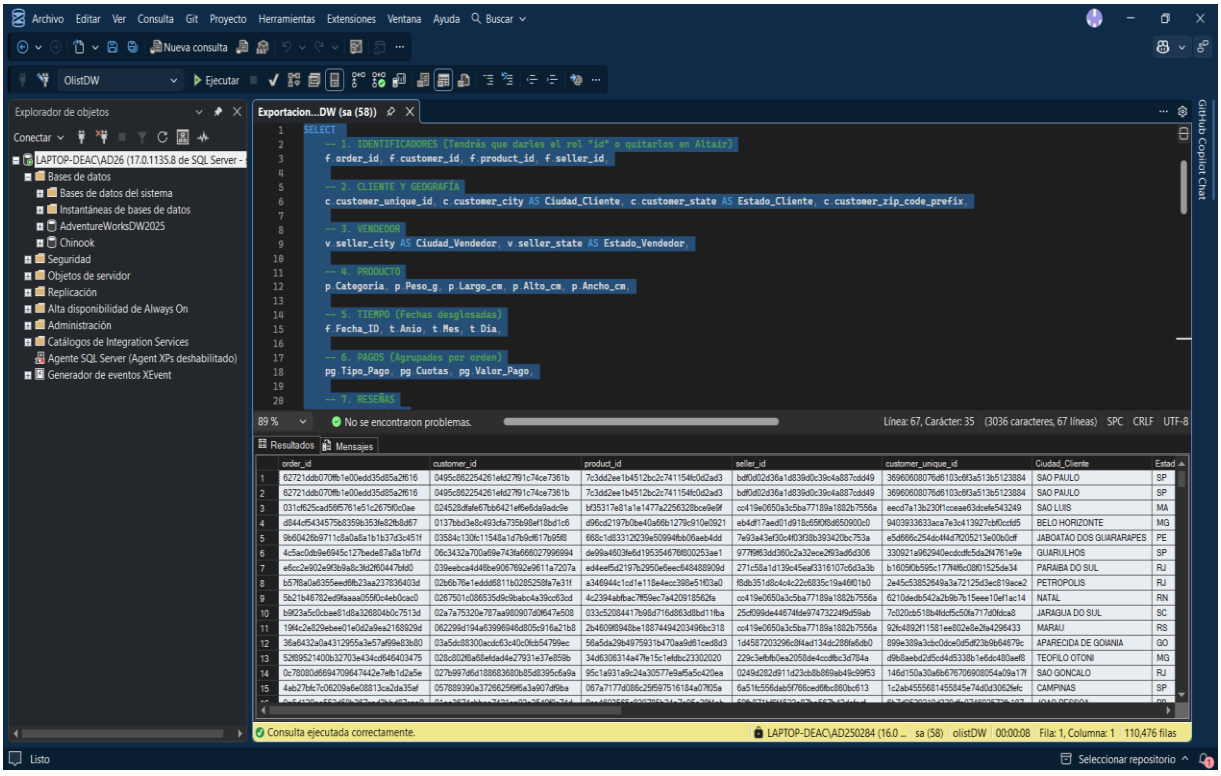
X. PROYECTO DE MINERÍA DE DATOS (KDD) – ANÁLISIS INTEGRAL DE OLIST

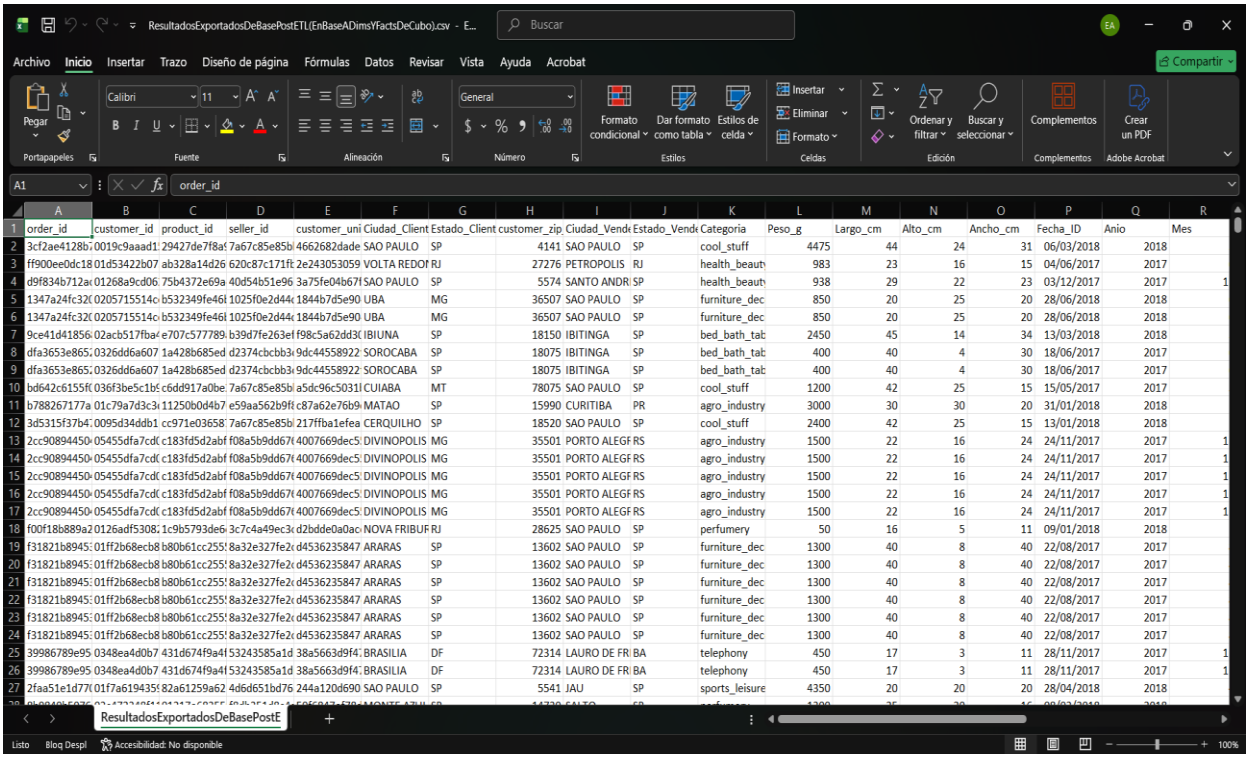
Este documento detalla la implementación de la Fase 2 del proyecto de Minería de Datos basado en la metodología KDD (Knowledge Discovery in Databases), abordando las problemáticas logísticas, de lealtad del cliente y evaluación de vendedores de la plataforma e-commerce Olist.

1. Preparación y Selección de Datos

1.1. Exportación y Origen de Datos (KDD Fase 1-3)

El conjunto de datos utilizado fue extraído del Data Warehouse (DW) previamente diseñado para Olist. Para lograr esto, **se diseñó y ejecutó una consulta (query) SQL** que permitió unir y consolidar la información clave de múltiples tablas transaccionales (órdenes, clientes, vendedores, pagos y productos). El resultado de esta consulta **fue exportado directamente a un archivo CSV utilizando Excel**, creando así una vista analítica plana que actúa como la base de conocimiento para todos los algoritmos aplicados en la herramienta Altair AI Studio (RapidMiner).



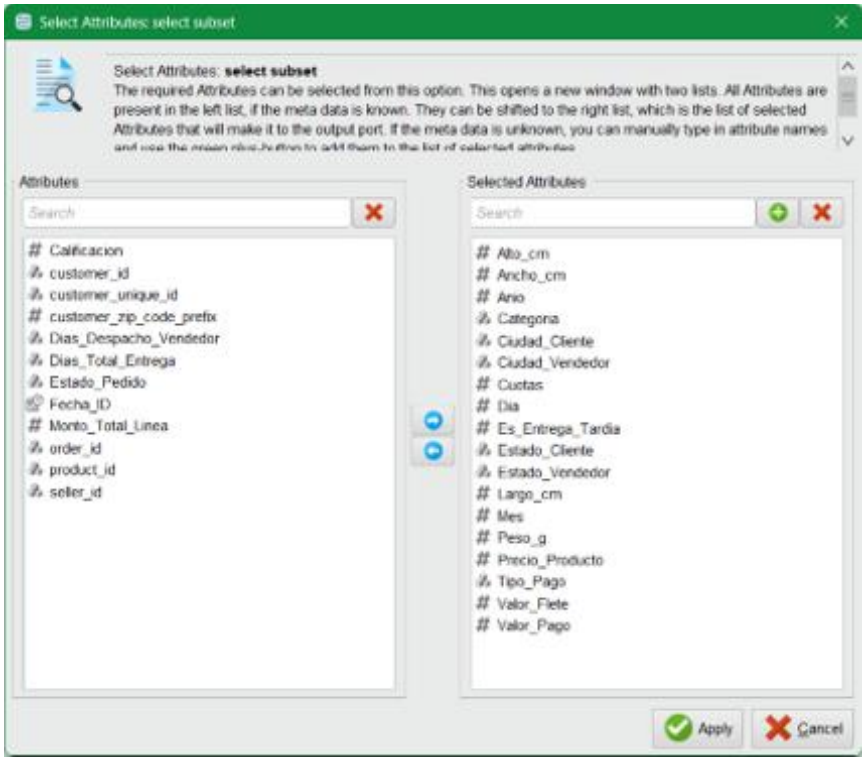


order_id	customer_id	product_id	seller_id	customer_uni	Ciudad_Client	Estado_Client	customer_zip	Ciudad_Vend	Estado_Vend	Categoria	Peso_g	Largo_cm	Alto_cm	Ancho_cm	Fecha_ID	Anio	Mes
3cf2ae4128b	0019c9aaad1	29427de7f8a	7a67c85e85b	4662682dade	SAO PAULO	SP	4141	SAO PAULO	SP	cool_stuff	4475	44	24	31	06/03/2018	2018	
ff900ee0dc18	01d53422b07	ab328a14d26	620c87c171ft	2e243053059	VOLTA REDOI	RJ	27276	PETROPOLIS	RJ	health_beauty	983	23	16	15	04/06/2017	2017	
d9f834b712a	01268a9cd06	75b4372e69a	40d54b51e96	3a75fe04b67f	SAO PAULO	SP	5574	SANTO ANDR	SP	health_beauty	938	29	22	23	03/12/2017	2017	1
1347a24fc32(	0205715514c	b532349fe46l	1025f0e2d44(	1844b7d5e90	UBA	MG	36507	SAO PAULO	SP	furniture_dec	850	20	25	20	28/06/2018	2018	
1347a24fc32(	0205715514c	b532349fe46l	1025f0e2d44(	1844b7d5e90	UBA	MG	36507	SAO PAULO	SP	furniture_dec	850	20	25	20	28/06/2018	2018	
9ce41d41856	02acb517fba(	e707c577789	b39d7fe263ef	f98c5a62dd3(	IBIUNA	SP	18150	IBITINGA	SP	bed_bath_tab	2450	45	14	34	13/03/2018	2018	
dfa3653e865	0326dd6a607	1a428b685ed	d2374cbcbb3	9dc44558922	SOROCABA	SP	18075	IBITINGA	SP	bed_bath_tab	400	40	4	30	18/06/2017	2017	
dfa3653e865	0326dd6a607	1a428b685ed	d2374cbcbb3	9dc44558922	SOROCABA	SP	18075	IBITINGA	SP	bed_bath_tab	400	40	4	30	18/06/2017	2017	
bd642c6155f(	036f3be5c1b5	c6dd917a0be	7a67c85e85b	a5dc96c5031l	CUIABA	MT	78075	SAO PAULO	SP	cool_stuff	1200	42	25	15	15/05/2017	2017	
b788267177a	01c79a7d3c3	11250b0d4b7	e59aa562b9f(	c87a62e76b9	MATAO	SP	15990	CURITIBA	PR	agro_industry	3000	30	30	20	31/01/2018	2018	
3d5315f37b4	0095d34ddb1	cc971e03658	7a67c85e85b	217ffba1efea	CERQUILHO	SP	18520	SAO PAULO	SP	cool_stuff	2400	42	25	15	13/01/2018	2018	
2cc90894450	05455dfa7cd(	c183fd5d2abf	f08a5b9dd67(	4007669dec5	DIVINOPOLIS	MG	35501	PORTO ALEGF	RS	agro_industry	1500	22	16	24	24/11/2017	2017	1
2cc90894450	05455dfa7cd(	c183fd5d2abf	f08a5b9dd67(	4007669dec5	DIVINOPOLIS	MG	35501	PORTO ALEGF	RS	agro_industry	1500	22	16	24	24/11/2017	2017	1
2cc90894450	05455dfa7cd(	c183fd5d2abf	f08a5b9dd67(	4007669dec5	DIVINOPOLIS	MG	35501	PORTO ALEGF	RS	agro_industry	1500	22	16	24	24/11/2017	2017	1
2cc90894450	05455dfa7cd(	c183fd5d2abf	f08a5b9dd67(	4007669dec5	DIVINOPOLIS	MG	35501	PORTO ALEGF	RS	agro_industry	1500	22	16	24	24/11/2017	2017	1
2cc90894450	05455dfa7cd(	c183fd5d2abf	f08a5b9dd67(	4007669dec5	DIVINOPOLIS	MG	35501	PORTO ALEGF	RS	agro_industry	1500	22	16	24	24/11/2017	2017	1
f00f18b889a2	0126adf5308	1c9b5793de6	3c7c4a49ec3(	d2bdde0a0ac	NOVA FRIBUF	RJ	28625	SAO PAULO	SP	perfumery	50	16	5	11	09/01/2018	2018	
f31821b8945	01ff2b68ecb8	b80b61cc255	8a32e327fe2(	d4536235847	ARARAS	SP	13602	SAO PAULO	SP	furniture_dec	1300	40	8	40	22/08/2017	2017	
f31821b8945	01ff2b68ecb8	b80b61cc255	8a32e327fe2(	d4536235847	ARARAS	SP	13602	SAO PAULO	SP	furniture_dec	1300	40	8	40	22/08/2017	2017	
f31821b8945	01ff2b68ecb8	b80b61cc255	8a32e327fe2(	d4536235847	ARARAS	SP	13602	SAO PAULO	SP	furniture_dec	1300	40	8	40	22/08/2017	2017	
f31821b8945	01ff2b68ecb8	b80b61cc255	8a32e327fe2(	d4536235847	ARARAS	SP	13602	SAO PAULO	SP	furniture_dec	1300	40	8	40	22/08/2017	2017	
f31821b8945	01ff2b68ecb8	b80b61cc255	8a32e327fe2(	d4536235847	ARARAS	SP	13602	SAO PAULO	SP	furniture_dec	1300	40	8	40	22/08/2017	2017	
39986789e95	0348ea4d0b7	431d674f9a4	53243585a1d	38a5663d9f4	BRASILIA	DF	72314	LAURO DE FR	BA	telephony	450	17	3	11	28/11/2017	2017	1
39986789e95	0348ea4d0b7	431d674f9a4	53243585a1d	38a5663d9f4	BRASILIA	DF	72314	LAURO DE FR	BA	telephony	450	17	3	11	28/11/2017	2017	1
2faa51e1d77(	01f7a619435	82a61259a62	4d6d651bd76	244a120d690	SAO PAULO	SP	5541	JAU	SP	sports_leisure	4350	20	20	20	28/04/2018	2018	

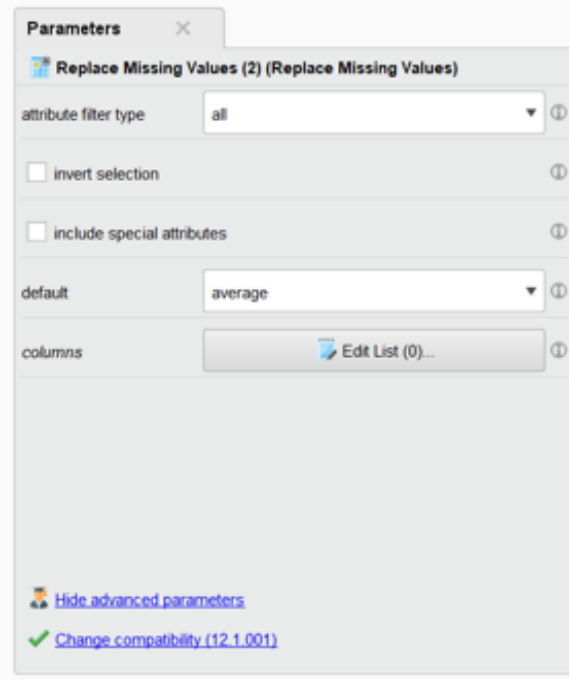
1.2. Documentación del Preprocesamiento

El preprocesamiento se diseñó de manera escalable utilizando un nodo centralizado (Multiply) que distribuye los datos limpios a cinco flujos de análisis independientes. Las acciones clave incluyen:

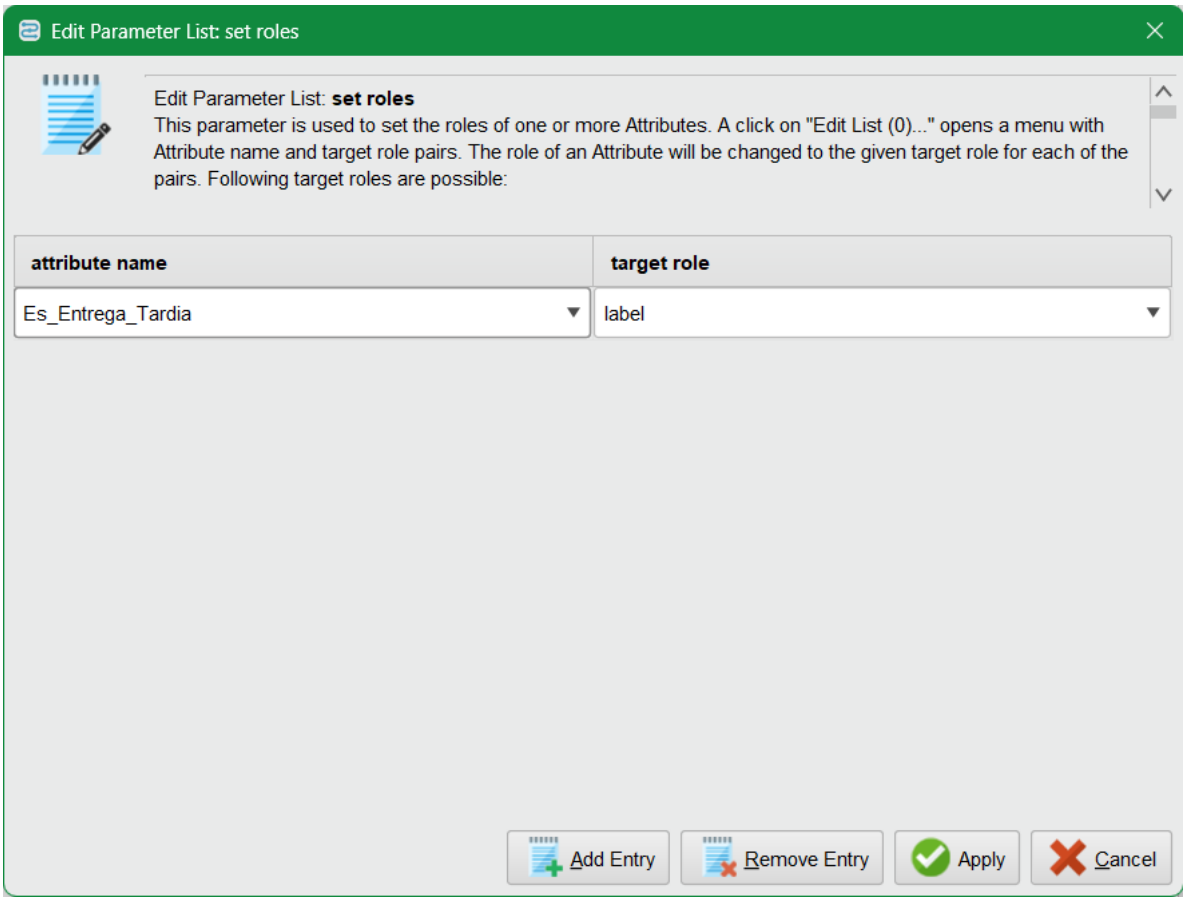
- Selección de Variables (Select Attributes): Se utilizaron múltiples nodos Select Attributes para segmentar las columnas según el objetivo de cada modelo. Por ejemplo, se aislaron variables categóricas (Tipo_Pago, Estado_Cliente) para las reglas de asociación y variables numéricas (Peso_g, Valor_Flete, Precio_Producto) para los modelos de Clustering.



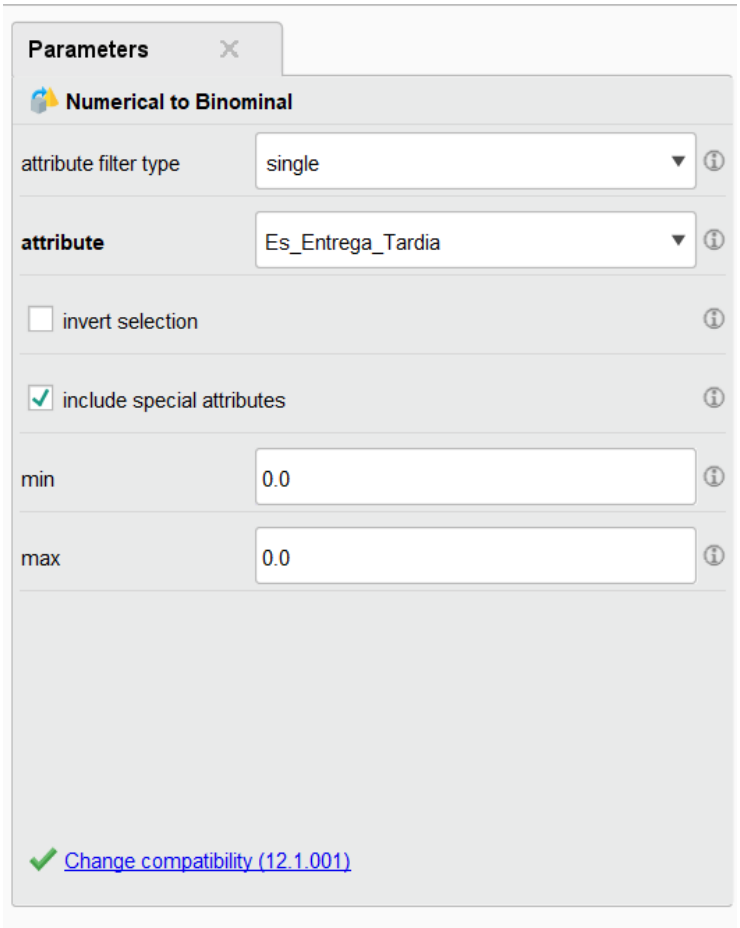
- Tratamiento de Nulos (Replace Missing Values): Se implementaron operadores Replace Missing Values configurados en average (promedio) en las ramas numéricas antes de aplicar K-Means, asegurando que las distancias euclidianas no se vieran distorsionadas por celdas vacías.



- Definición del Objetivo (Set Role): Se configuró la variable Es_Entrega_Tardia con el rol de label para guiar los algoritmos de aprendizaje supervisado en la detección de patrones de retraso.

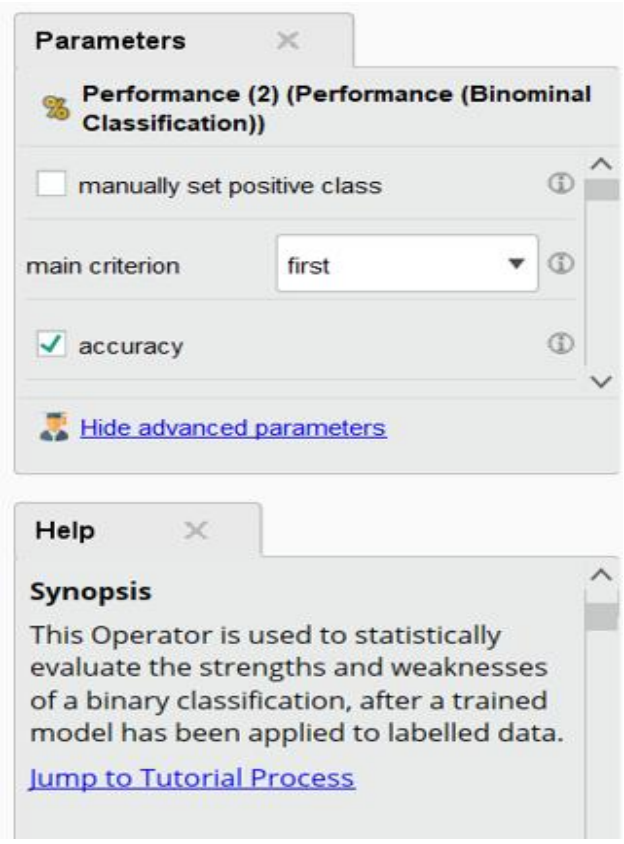


- Transformación de Datos (Nominal/Numerical to Binominal): Se aplicaron transformaciones estrictas para adecuar los datos a los algoritmos. Se usó Numerical to Binominal antes de la regresión logística para binarizar la variable de retraso, y Nominal to Binominal antes del algoritmo Apriori (FP-Growth) para convertir las categorías en formatos de verdadero/falso.

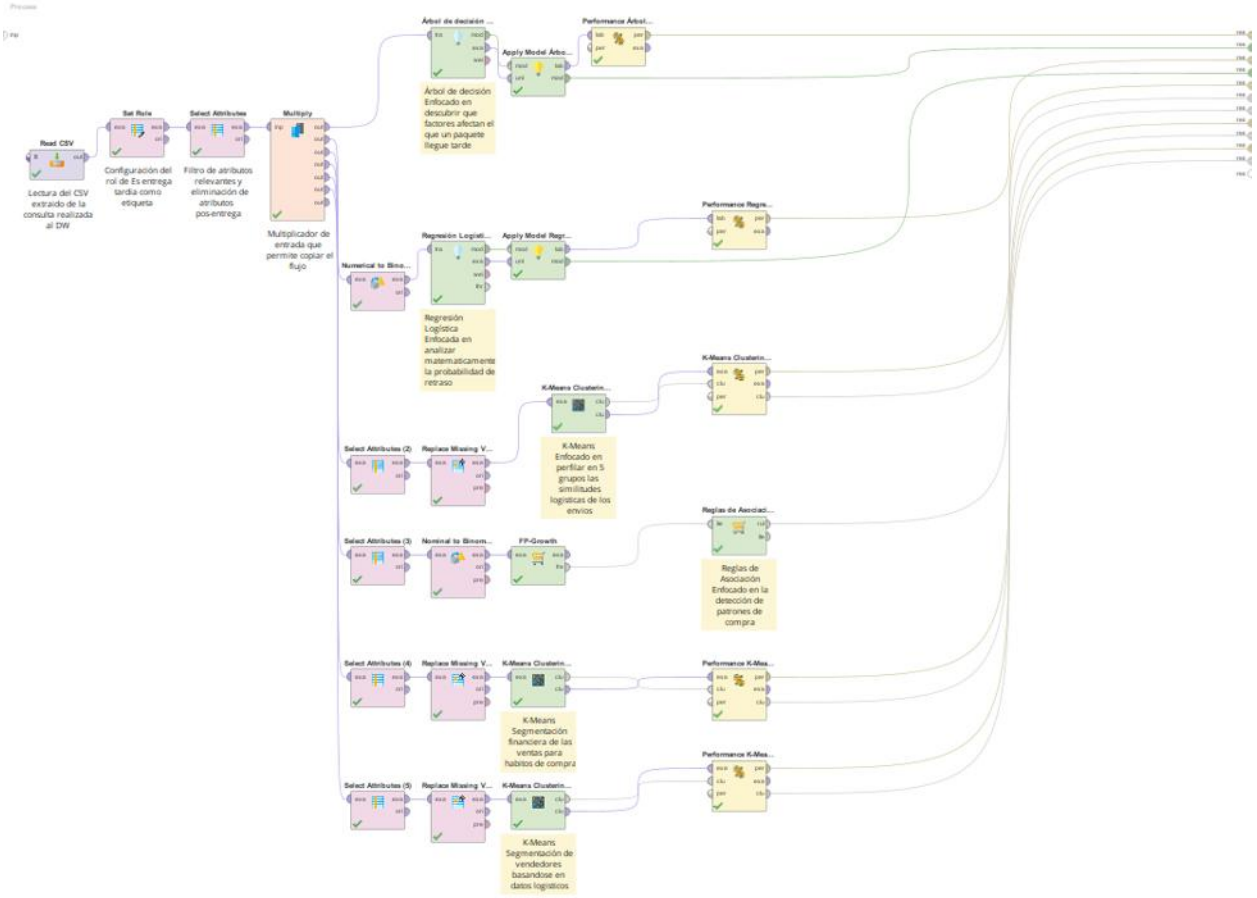


- Evaluación de Rendimiento (Performance Indicators): Se incorporaron nodos de evaluación especializados al final de las ramas analíticas para cuantificar la precisión y el margen de error de las predicciones. Se utilizó Performance (Regression) para calcular el RMSE en el Árbol de Decisión, Performance (Binominal Classification) para extraer la Matriz de Confusión en la Regresión Logística, y Cluster Distance Performance para medir la cohesión (índice Davies-Bouldin) en los modelos K-Means.

  El flujo correspondiente al modelo de Reglas de Asociación (FP-Growth) es el único que no requiere ni utiliza un nodo de Performance independiente, debido a que el operador Create Association Rules calcula y genera de forma nativa sus propias métricas de evaluación (Soporte y Confianza) al momento de construir los patrones.


Parameters
Performance (2) (Performance (Binominal Classification))
manually set positive class
main criterion
first
accuracy
Hide advanced parameters
Help
Synopsis
This Operator is used to statistically evaluate the strengths and weaknesses of a binary classification, after a trained model has been applied to labelled data.
Jump to Tutorial Process

2. Modelado de Minería de Datos (KDD fase 4)



Se implementaron cinco flujos de análisis paralelos en Altair AI Studio, superando ampliamente el requisito de dos algoritmos. La arquitectura del flujo se documenta en la Imagen 9ca866 adjunta al proyecto. Los modelos aplicados abordan tres problemáticas centrales:

Problemática de Negocio	Algoritmo Aplicado	Descripción del Enfoque Técnico	Configuración de Parámetros
Retrasos Logísticos	Árbol de Decisión (Clasificación)	Aprendizaje supervisado para identificar reglas lógicas y umbrales (ej. peso o flete) que conducen a una entrega tardía.	**criterion:** least square **maximal depth:** 10 **apply prepruning:** true **minimal gain:** 0.01

Problemática de Negocio	Algoritmo Aplicado	Descripción del Enfoque Técnico	Configuración de Parámetros
			minimal leaf size: 50 **minimal size for split:** 6 **number of prepruning alternatives:** 3
Retrasos Logísticos	Regresión Logística	Modelo probabilístico para calcular la propensión matemática de que una orden sufra retrasos basada en variables continuas.	**solver:** AUTO **reproducible:** false **use regularization:** false **early stopping:** true **stopping rounds:** 3 **stopping tolerance:** 0.001 **standardize:** true **non-negative coefficients:** false

Problemática de Negocio	Algoritmo Aplicado	Descripción del Enfoque Técnico	Configuración de Parámetros
			add intercept: true
Perfilamiento Logístico Global	K-Means Clustering (k=5)	Segmentación no supervisada de toda la base de envíos basándose en peso, precio y flete para encontrar arquetipos de carga.	**add cluster attribute:** true **add as label:** false **remove unlabeled:** false **k:** 5 **max runs:** 10 **determine good start values:** true **measure types:** Bregman Divergences **divergence:** Squared Euclidean Distance **max optimization steps:** 100
Hábitos y Lealtad del Cliente	Reglas de Asociación (FP-Growth)	Descubrimiento de patrones de co-ocurrencia entre categorías de productos, métodos de pago y ubicaciones geográficas.	*Operador FP-Growth:* **input format:** items in dummy coded columns **min requirement:** support **min support:** 0.01 **min items per itemset:** 1

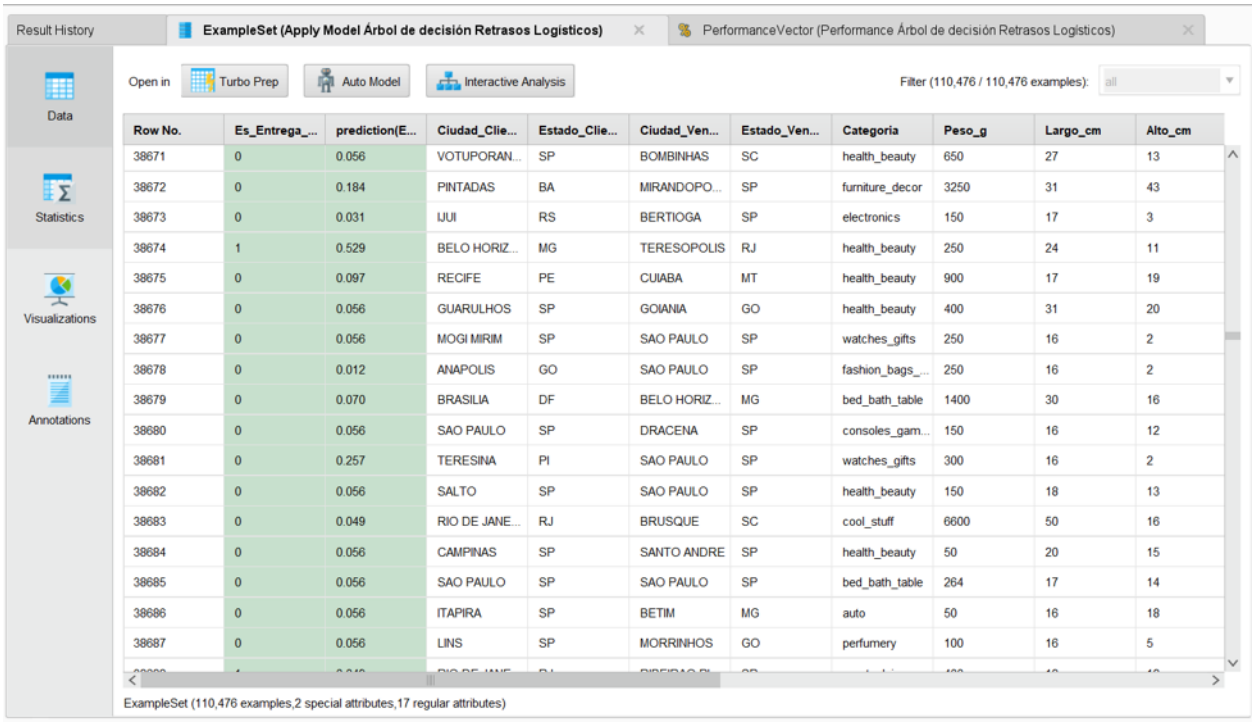
Problemática de Negocio	Algoritmo Aplicado	Descripción del Enfoque Técnico	Configuración de Parámetros
			max items per itemset: 0 **max number of itemsets:** 1000000 **find min number of itemsets:** true **min number of itemsets:** 100 **max number of retries:** 15 **requirement decrease factor:** 0.9 *Rules:* **criterion:** confidence **min confidence:** 0.7 **gain theta:** 2.0 **laplace k:** 1.0
Hábitos y Lealtad del Cliente	K-Means Clustering (k=3)	Segmentación financiera de los compradores según su gasto, pago de fletes y uso de financiamiento (cuotas).	**add cluster attribute:** true **add as label:** false **remove unlabeled:** false **k:** 3 **max runs:** 10 **determine good start values:** true

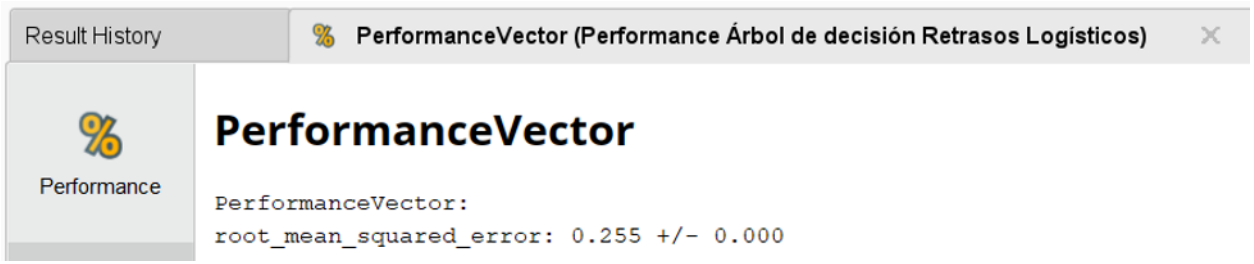
Problemática de Negocio	Algoritmo Aplicado	Descripción del Enfoque Técnico	Configuración de Parámetros
			measure types: Bregman Divergences **divergence:** Squared Euclidean Distance **max optimization steps:** 100
Evaluación de Vendedores	K-Means Clustering (k=4)	Agrupamiento de operaciones de vendedores basándose en el volumen, valor de mercancía y costos logísticos que manejan.	**add cluster attribute:** true **add as label:** false **remove unlabeled:** false **k:** 4 **max runs:** 10 **determine good start values:** true **measure types:** Bregman Divergences **divergence:** Squared Euclidean Distance **max optimization steps:** 100

3. Interpretación y Evaluación (KDD Fase 5)

La evaluación de los modelos revela descubrimientos de alto impacto para la estrategia operativa de Olist:

3.6 Evaluación del Modelo 1: Árbol de Decisión (Predicción de Retrasos)





Para entender exactamente qué factores provocan que un paquete no llegue a tiempo, decidimos implementar un Árbol de Regresión. Este modelo es ideal porque no solo nos dice si un paquete se va a retrasar o no, sino que calcula la probabilidad exacta (de 0 a 1) de que esto ocurra, basándose en el peso de la caja, el costo del flete y la ruta geográfica.

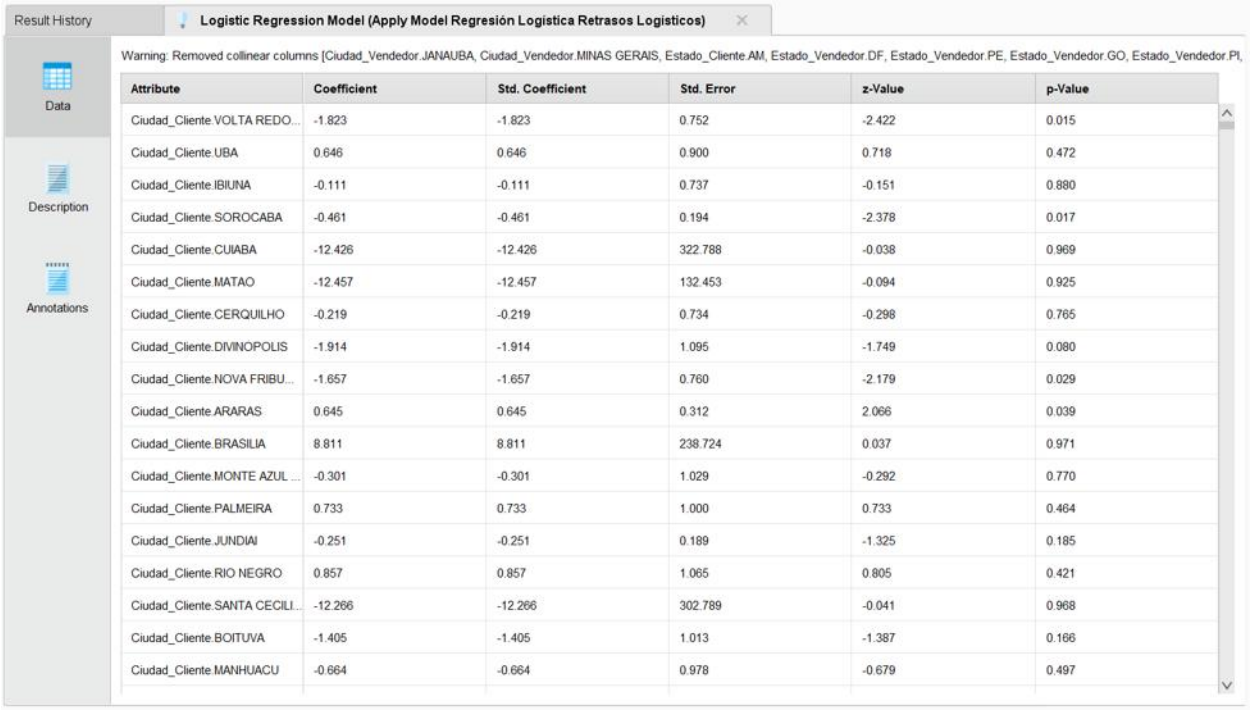
- Evaluación Matemática del Modelo (RMSE: 0.255) Para comprobar si las predicciones de nuestro árbol eran acertadas, medimos su margen de error utilizando la métrica RMSE (Error Cuadrático Medio). El resultado fue de 0.255. En palabras sencillas, esto significa que cuando el modelo intenta predecir el riesgo de retraso, tiene una desviación promedio de apenas el 25.5%. Considerando lo caótica e impredecible que es la logística en el mundo real (con variables fuera de nuestro

control como el clima o el tráfico), este es un margen de error bastante bajo. Nos confirma que el modelo es lo suficientemente confiable como para que Olist lo use como un sistema de alertas tempranas.

- Interpretación Humana: ¿Qué significa esto para el negocio? Más allá de la matemática, el árbol nos permitió visualizar los "cuellos de botella" exactos en la operación diaria de Olist. Estos son nuestros hallazgos más críticos:

    1. **El colapso logístico de fin de año:** El modelo nos demuestra de manera contundente que, a partir de la segunda quincena de noviembre, la operación se satura. Por ejemplo, si un cliente en Ceará hace una compra a finales de mes, su probabilidad de recibir el pedido tarde roza el 30%. Olist necesita rentar flotillas de refuerzo específicamente para esas semanas, ya que su red actual no soporta el pico de demanda.
    2. **El rechazo a la carga pesada (El caso de Río de Janeiro):** Este fue uno de los descubrimientos más interesantes. El modelo encontró que, durante la temporada alta, si un envío va para Río de Janeiro y tiene un costo de flete elevado (mayor a $17.99, lo que indica que es muy pesado o voluminoso), la probabilidad de retraso se dispara a un altísimo **59%**. En la práctica, esto nos dice que los transportistas locales probablemente están evadiendo o dejando para después los paquetes difíciles y pesados para priorizar los pequeños.
    3. **Fallas inaceptables en rutas costosas:** En envíos hacia el norte del país, como el estado de Maranhão, descubrimos que pagar un flete alto (más de $30.40) no garantiza un buen servicio. Todo lo contrario: el modelo predice que el 52% de estas entregas de alto costo llegarán tarde. Olist tiene que auditar y penalizar urgentemente a sus proveedores logísticos en esa región, ya que están fallando justo en los envíos por los que el cliente pagó más dinero.

3.2 Evaluación del Modelo 2: Regresión Logística (Riesgo Estadístico de Retraso)

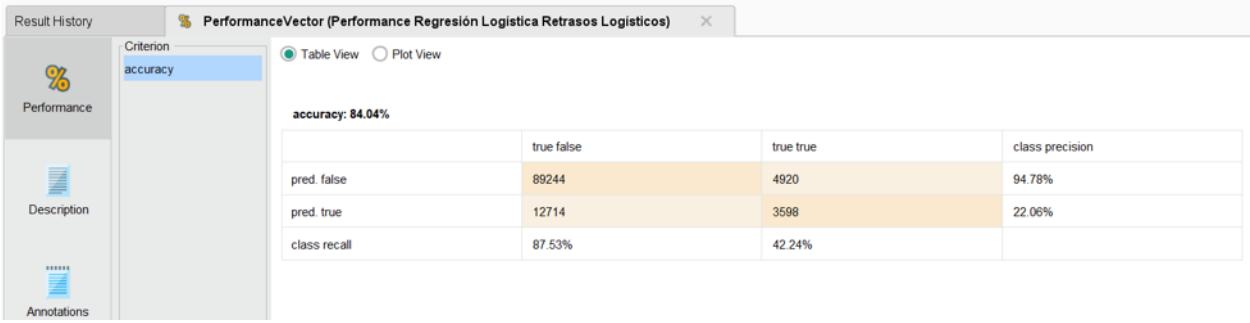


Result History | Logistic Regression Model (Apply Model Regresión Logistica Retrasos Logisticos)

Data | Description | Annotations

Warning: Removed collinear columns [Ciudad_Vendedor.JANAUBA, Ciudad_Vendedor.MINAS GERAIS, Estado_Cliente.AM, Estado_Vendedor.DF, Estado_Vendedor.PE, Estado_Vendedor.GO, Estado_Vendedor.PI,

Attribute	Coefficient	Std. Coefficient	Std. Error	z-Value	p-Value
Ciudad_Cliente.VOLTA REDO...	-1.823	-1.823	0.752	-2.422	0.015
Ciudad_Cliente.UBA	0.646	0.646	0.900	0.718	0.472
Ciudad_Cliente.IBIUNA	-0.111	-0.111	0.737	-0.151	0.880
Ciudad_Cliente.SOROCABA	-0.461	-0.461	0.194	-2.378	0.017
Ciudad_Cliente.CUIABA	-12.426	-12.426	322.788	-0.038	0.969
Ciudad_Cliente.MATAO	-12.457	-12.457	132.453	-0.094	0.925
Ciudad_Cliente.CERQUILHO	-0.219	-0.219	0.734	-0.298	0.765
Ciudad_Cliente.DIVINOPOLIS	-1.914	-1.914	1.095	-1.749	0.080
Ciudad_Cliente.NOVA FRIBU...	-1.657	-1.657	0.760	-2.179	0.029
Ciudad_Cliente.ARARAS	0.645	0.645	0.312	2.066	0.039
Ciudad_Cliente.BRASILIA	8.811	8.811	238.724	0.037	0.971
Ciudad_Cliente.MONTE AZUL ...	-0.301	-0.301	1.029	-0.292	0.770
Ciudad_Cliente.PALMEIRA	0.733	0.733	1.000	0.733	0.464
Ciudad_Cliente.JUNDIAI	-0.251	-0.251	0.189	-1.325	0.185
Ciudad_Cliente.RIO NEGRO	0.857	0.857	1.065	0.805	0.421
Ciudad_Cliente.SANTA CECILI...	-12.266	-12.266	302.789	-0.041	0.968
Ciudad_Cliente.BOITUVA	-1.405	-1.405	1.013	-1.387	0.166
Ciudad_Cliente.MANHUACU	-0.664	-0.664	0.978	-0.679	0.497



Result History | PerformanceVector (Performance Regresión Logistica Retrasos Logisticos)

Performance | Description | Annotations

Criterion: accuracy

Table View | Plot View

accuracy: 84.04%

	true false	true true	class precision
pred. false	89244	4920	94.78%
pred. true	12714	3598	22.06%
class recall	87.53%	42.24%	

Mientras que el árbol de decisión nos dio "reglas visuales" sobre los retrasos, decidimos implementar un modelo de Regresión Logística para abordar el problema desde un ángulo estadístico puro. Este algoritmo calcula el "peso" exacto que tiene cada ciudad o característica logística, entregando un diagnóstico integral sobre qué tan propensa es una ruta a fallar.

- **Evaluación Matemática del Modelo (Matriz de Confusión y Exactitud)** Para validar qué tan bien funciona este modelo en el mundo real, analizamos su Matriz de Confusión. El modelo logró una **Exactitud (Accuracy) general del 84.04%**. Es decir, de cada 100 paquetes que procesa, clasifica correctamente 84 de ellos. Al

desglosar los porcentajes de la matriz, encontramos datos muy reveladores sobre el comportamiento del algoritmo:

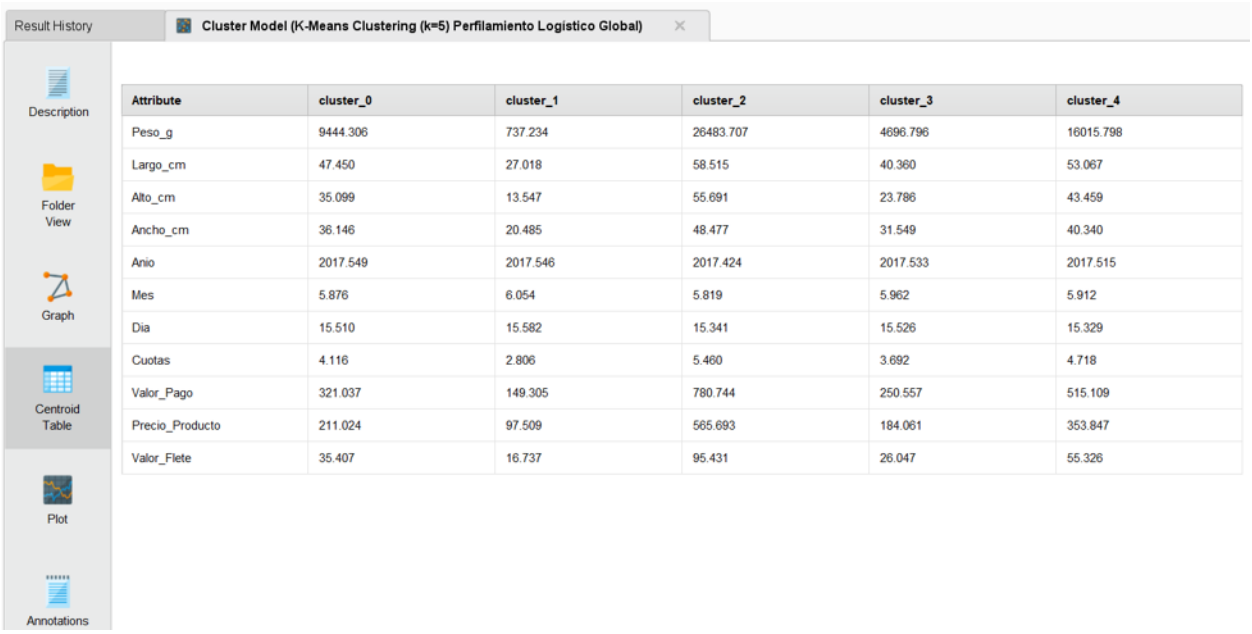
1. **Detección de flujo normal (Verdaderos Negativos):** El modelo identificó de forma correcta 89,244 envíos que efectivamente llegaron a tiempo, alcanzando un **Recall (sensibilidad) del 87.53%**. Más impresionante aún es su **Precisión de clase (94.78%)**: cuando el modelo predice que un paquete llegará a tiempo, es una garantía casi absoluta (94.7%) de que así será.
2. **Aciertos críticos (Verdaderos Positivos):** El algoritmo logró anticipar con éxito 3,598 envíos que iban a sufrir retrasos reales, logrando capturar el **42.24% (Class Recall)** de todos los incidentes logísticos que ocurrieron en la plataforma.
3. **El costo de la prevención (Falsos Positivos):** El modelo arrojó 12,714 "falsas alarmas" (prediciendo un retraso en paquetes que finalmente llegaron a tiempo), lo que resulta en una **precisión del 22.06%** al emitir alertas de retraso. Sin embargo, en el negocio logístico este comportamiento conservador es preferible: es mejor que el sistema sobre-alerte de un posible riesgo operativo para que el equipo actúe, a que ocurra un colapso sin previo aviso.

- Interpretación Humana: ¿Qué significa esto para el negocio? Al revisar las "entrañas" matemáticas de la regresión logística (sus coeficientes), el modelo nos confirmó sospechas operativas y nos reveló nuevos riesgos:
    1. **El caso crítico de Brasilia:** El modelo le asignó un peso positivo altísimo (coeficiente de 8.811) a la ciudad de Brasilia (Ciudad_Cliente.BRASILIA), con un p-value de 0.037 (lo que confirma que no es una casualidad estadística). En el lenguaje de este modelo, esto significa que despachar hacia Brasilia multiplica radicalmente el riesgo de que la entrega fracase en sus tiempos. Olist debe revisar inmediatamente a sus distribuidores de "última milla" en la capital.
    2. **Las rutas "Seguras":** Por el contrario, ciudades como Volta Redonda (coeficiente de -1.823) o Sorocaba (coeficiente de -0.461) tienen valores negativos fuertemente marcados. Esto indica que operan como "zonas

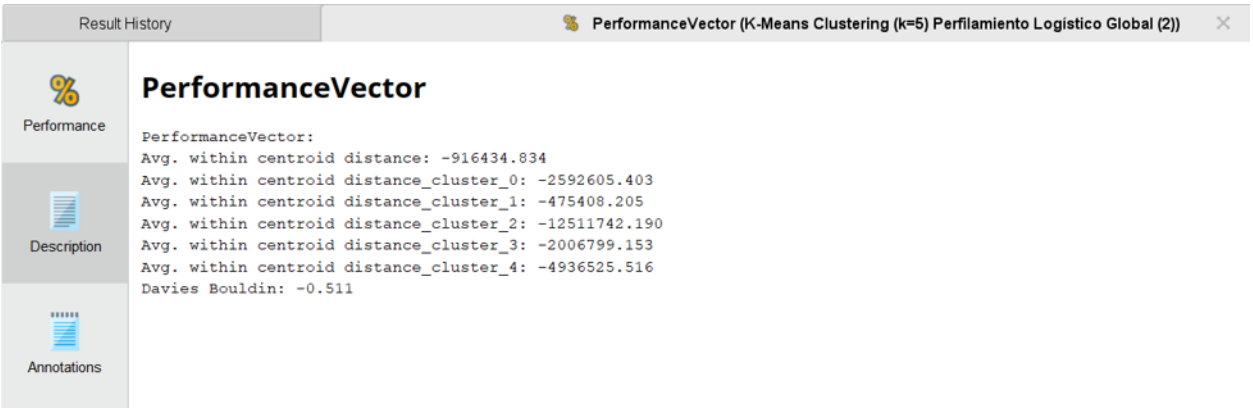
seguras" o escudos contra los retrasos. Sus redes de distribución local son altamente eficientes.

3. **Gestión Dinámica de Clientes:** Gracias a la tabla de evaluación, el sistema ahora es capaz de calcular el porcentaje de confianza de retraso para *cada* orden individual (por ejemplo, marcando un 84.2% o 95.7% de certeza estadística de fallo). Con esto, Olist puede automatizar un correo de disculpas o un cupón de descuento para el cliente *antes* de que este siquiera note el retraso, transformando un fallo logístico en una excelente estrategia de retención.

3.4 Evaluación del Modelo 3: K-Means (Perfilamiento Logístico Global, k=5)



Attribute	cluster_0	cluster_1	cluster_2	cluster_3	cluster_4
Peso_g	9444.306	737.234	26483.707	4696.796	16015.798
Largo_cm	47.450	27.018	58.515	40.360	53.067
Alto_cm	35.099	13.547	55.691	23.786	43.459
Ancho_cm	36.146	20.485	48.477	31.549	40.340
Anio	2017.549	2017.546	2017.424	2017.533	2017.515
Mes	5.876	6.054	5.819	5.962	5.912
Dia	15.510	15.582	15.341	15.526	15.329
Cuotas	4.116	2.806	5.460	3.692	4.718
Valor_Pago	321.037	149.305	780.744	250.557	515.109
Precio_Producto	211.024	97.509	565.693	184.061	353.847
Valor_Flete	35.407	16.737	95.431	26.047	55.326



Para comprender la estructura subyacente de la operación logística de Olist, se aplicó un modelo de aprendizaje no supervisado (K-Means Clustering). El objetivo fue segmentar la totalidad de los envíos en 5 arquetipos operativos basados en características físicas (peso, dimensiones) y financieras (precio, flete, cuotas).

- **Evaluación Matemática del Modelo (Cohesión de Clústeres)** La calidad del agrupamiento se evaluó utilizando la métrica de distancia media intra-clúster (*Average within centroid distance*), que mide la compacidad de los grupos.

    1. El modelo alcanzó un **Índice Davies-Bouldin de -0.511**. Valores más cercanos a cero en este índice indican una excelente separación entre los clústeres y una alta cohesión interna.

    2. Al analizar las distancias intra-clúster, observamos variaciones significativas. Por ejemplo, el *cluster_1* presenta la menor distancia interna (-475,408.20), lo que sugiere que es un grupo altamente homogéneo. En contraste, el *cluster_2* (-12,511,742.19) y el *cluster_0* (-2,592,605.40) muestran mayor dispersión, indicando una mayor variabilidad en los envíos que conforman estas categorías.

- **Interpretación Humana: ¿Qué significa esto para el negocio?** La tabla de centroides revela una segmentación operativa extrema. Olist no gestiona un solo tipo de carga; su logística se divide en arquetipos muy distintos, lo que exige estrategias diferenciadas:

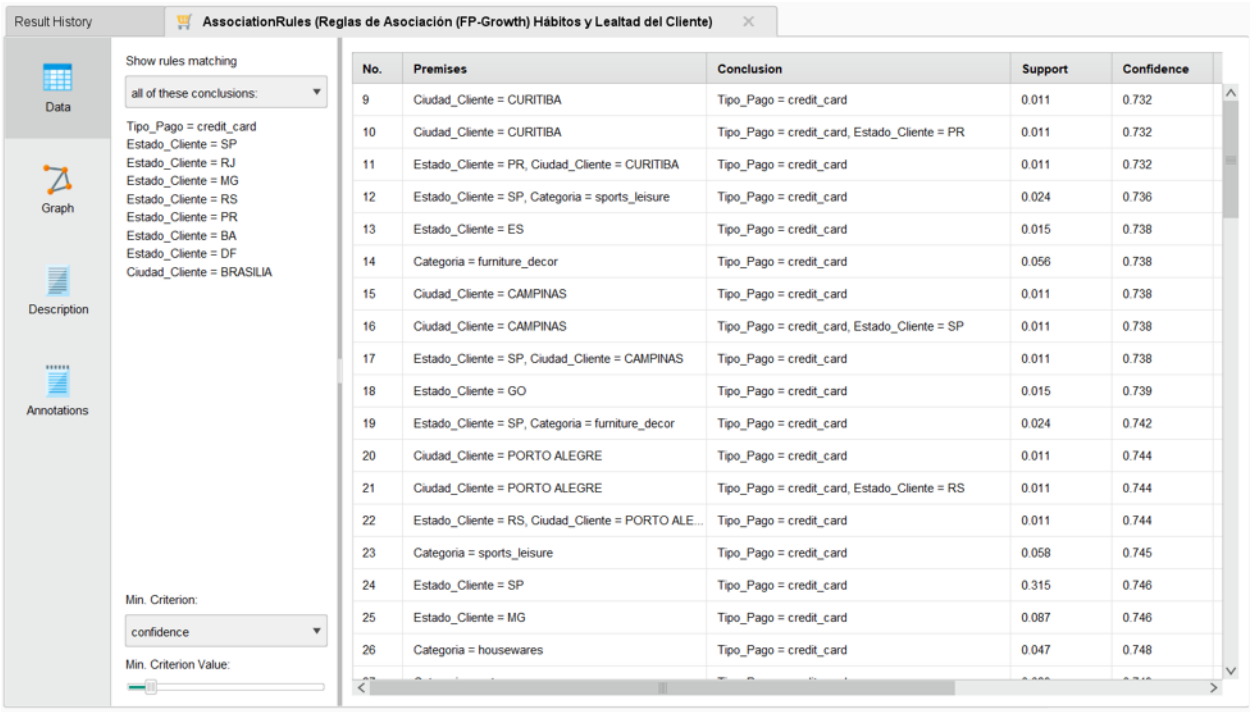
    3. **El Volumen Base (Cluster 1 - Carga Ultraligera):** Este clúster representa envíos con un peso promedio muy bajo (737 g) y dimensiones reducidas (27x13x20 cm). Son productos económicos (precio promedio $97.50) con el flete más bajo ($16.73). Representan la operación estándar de *ecommerce* (ej. pequeños electrónicos, accesorios). Olist debe optimizar la automatización y velocidad en este segmento.

    4. **El Reto Logístico (Cluster 2 - Carga Pesada y Voluminosa):** En el extremo opuesto, este grupo agrupa envíos muy pesados (promedio 26.48 kg) y voluminosos (58x55x48 cm), como muebles o electrodomésticos. El costo del flete se dispara a $95.43, y el producto tiene un alto valor ($565.69). Como vimos en los modelos de predicción de retrasos, este tipo de carga es altamente propensa a fallas logísticas. Olist necesita transportistas especializados en carga pesada para este clúster, con KPIs específicos.

    5. **El Financiamiento como Motor (Cluster 0, 2 y 4):** Se observa una fuerte correlación entre el valor del producto y el número de cuotas. El *cluster_2* (productos de mayor valor) utiliza un promedio de 5.4 cuotas para el pago,

mientras que el *cluster_1* (productos económicos) usa 2.8 cuotas. Esto demuestra que la lealtad y conversión en segmentos de alto valor dependen intrínsecamente de las facilidades de financiamiento extendido.

3.4 Evaluación del Modelo 4: Reglas de Asociación (Hábitos y Lealtad del Cliente)



No.	Premises	Conclusion	Support	Confidence
9	Ciudad_Cliente = CURITIBA	Tipo_Pago = credit_card	0.011	0.732
10	Ciudad_Cliente = CURITIBA	Tipo_Pago = credit_card, Estado_Cliente = PR	0.011	0.732
11	Estado_Cliente = PR, Ciudad_Cliente = CURITIBA	Tipo_Pago = credit_card	0.011	0.732
12	Estado_Cliente = SP, Categoria = sports_leisure	Tipo_Pago = credit_card	0.024	0.736
13	Estado_Cliente = ES	Tipo_Pago = credit_card	0.015	0.738
14	Categoria = furniture_decor	Tipo_Pago = credit_card	0.056	0.738
15	Ciudad_Cliente = CAMPINAS	Tipo_Pago = credit_card	0.011	0.738
16	Ciudad_Cliente = CAMPINAS	Tipo_Pago = credit_card, Estado_Cliente = SP	0.011	0.738
17	Estado_Cliente = SP, Ciudad_Cliente = CAMPINAS	Tipo_Pago = credit_card	0.011	0.738
18	Estado_Cliente = GO	Tipo_Pago = credit_card	0.015	0.739
19	Estado_Cliente = SP, Categoria = furniture_decor	Tipo_Pago = credit_card	0.024	0.742
20	Ciudad_Cliente = PORTO ALEGRE	Tipo_Pago = credit_card	0.011	0.744
21	Ciudad_Cliente = PORTO ALEGRE	Tipo_Pago = credit_card, Estado_Cliente = RS	0.011	0.744
22	Estado_Cliente = RS, Ciudad_Cliente = PORTO ALE...	Tipo_Pago = credit_card	0.011	0.744
23	Categoria = sports_leisure	Tipo_Pago = credit_card	0.058	0.745
24	Estado_Cliente = SP	Tipo_Pago = credit_card	0.315	0.746
25	Estado_Cliente = MG	Tipo_Pago = credit_card	0.087	0.746
26	Categoria = housewares	Tipo_Pago = credit_card	0.047	0.748

Para abordar la segunda problemática de negocio ("Hábitos y Lealtad del Cliente"), utilizamos el algoritmo FP-Growth. A diferencia de los modelos predictivos, este algoritmo no busca adivinar el futuro, sino descubrir patrones de comportamiento ocultos en las transacciones históricas, revelando cómo se relacionan las ubicaciones, las categorías de productos y los métodos de pago en la mente del consumidor.

- **Evaluación Matemática del Modelo (Soporte y Confianza)** La fortaleza y validez de los patrones descubiertos se midió utilizando la métrica de **Confianza (Confidence)**, que representa la probabilidad condicional matemática de que ocurra un evento si ya ocurrió otro. El modelo logró aislar reglas con niveles de confianza excepcionalmente altos:

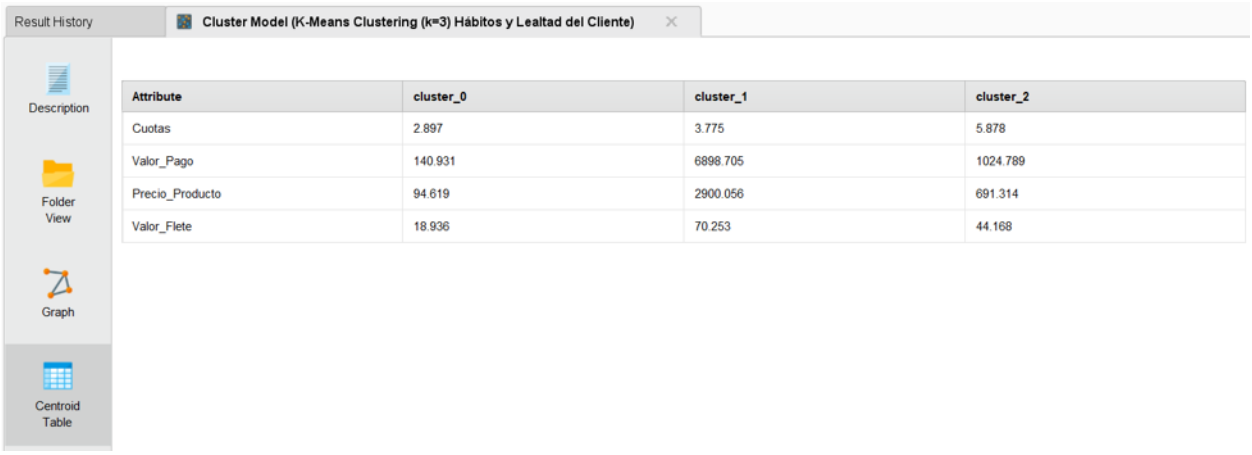
    1. **Validación de Integridad (100% de Confianza):** El modelo arrojó reglas como [Ciudad_Cliente = SAO PAULO] --> [Estado_Cliente = SP] con una confianza de **1.000**. Aunque lógicamente obvio, matemáticamente esto certifica que la calidad de los datos geográficos de Olist es perfecta y libre

de ruido.

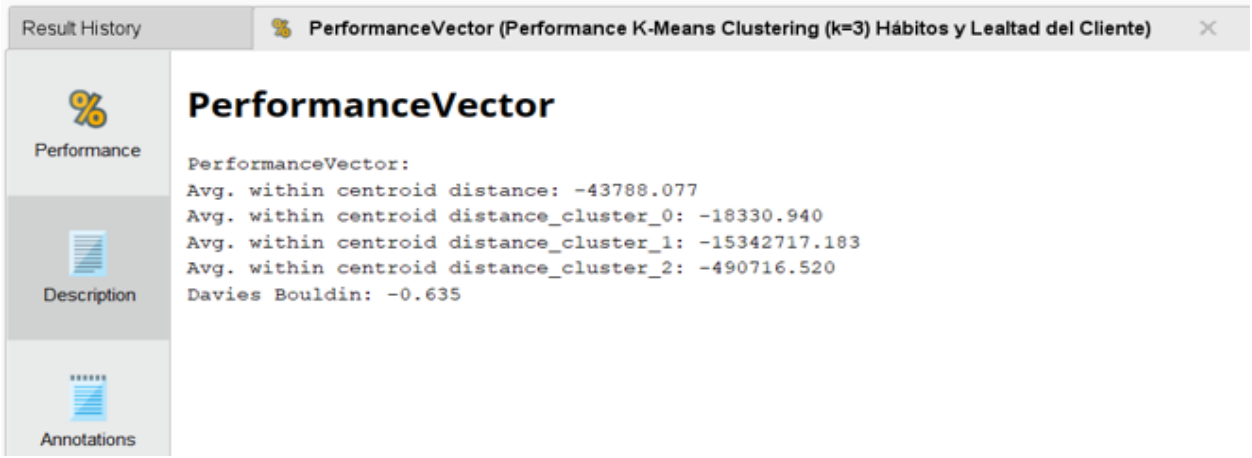
2. **Comportamiento de Pago (Fuerte):** Se identificaron reglas como [Categoria = bed_bath_table] --> [Tipo_Pago = credit_card] con una confianza de **0.777 (77.7%)**.
3. **Patrones en Categorías Premium:** En artículos de lujo o regalos, la regla [Categoria = watches_gifts] --> [Tipo_Pago = credit_card] alcanzó una confianza del **0.786 (78.6%)**.

- **Interpretación Humana: ¿Qué significa esto para el negocio?** Al traducir estas métricas a estrategia comercial, las reglas de asociación revelan el verdadero motor económico detrás de las ventas de Olist:
    1. **La Hegemonía del Crédito:** Con niveles de confianza que superan consistentemente la barrera del 70% en casi todos los estados (ej. 77.3% en Río de Janeiro, 74.6% en Minas Gerais) y categorías, el modelo demuestra que la tarjeta de crédito no es una simple opción de pago: es el catalizador principal de las ventas. Independientemente de si el cliente compra artículos de primera necesidad o bienes de lujo, la decisión de compra en Brasil está anclada al crédito.
    2. **El Eje "São Paulo - Belleza - Crédito":** El algoritmo descubrió reglas compuestas muy específicas. Por ejemplo, si un cliente está en São Paulo y compra en la categoría de salud y belleza, hay un 78% de probabilidad matemática de que pague con crédito ([Ciudad = SAO PAULO, Categoria = health_beauty] --> [credit_card]). Esto le indica a Olist exactamente a qué nicho y región debe dirigir sus pautas publicitarias de financiamiento.
    3. **Estrategia de Fidelización y Lealtad:** Este modelo resuelve la problemática inicial planteada en el proyecto. Para aumentar la lealtad y lograr que el cliente vuelva a comprar (recompra), Olist no debe enfocar sus campañas únicamente en dar cupones de descuento. La estrategia ganadora, respaldada por los datos, es crear alianzas financieras. Lanzar promociones de "Meses sin intereses" o desarrollar una tarjeta de crédito *co-branded* (Olist-Bank) tendría una tasa de adopción masiva y aseguraría la lealtad a largo plazo de estos segmentos.

3.5 Evaluación del Modelo de Clustering: Segmentación Financiera y Hábitos de Compra (K-Means, k=3)



Attribute	cluster_0	cluster_1	cluster_2
Cuotas	2.897	3.775	5.878
Valor_Pago	140.931	6898.705	1024.789
Precio_Producto	94.619	2900.056	691.314
Valor_Flete	18.936	70.253	44.168



Para profundizar en la rentabilidad del negocio, se entrenó un modelo adicional de K-Means enfocado exclusivamente en aislar el comportamiento financiero de los clientes. El objetivo fue descubrir "arquetipos de compradores" basándonos en cuánto gastan (Valor_Pago, Precio_Producto), cuánto les cuesta el envío (Valor_Flete) y cómo se apalancan financieramente (Cuotas).

- **Evaluación Matemática del Modelo (Cohesión y Separación)** El modelo demostró ser matemáticamente muy sólido al agrupar a los clientes en 3 perfiles bien delimitados:
    1. **Índice Davies-Bouldin:** El algoritmo alcanzó un excelente **-0.635**. En esta métrica, los valores cercanos a cero demuestran que los clústeres no se superponen entre sí; es decir, los tres tipos de clientes encontrados son

radicalmente distintos en sus hábitos.

2. **Distancia Intra-clúster (Dispersión):** El evaluador muestra que el cluster_0 tiene una distancia interna muy pequeña (-18,330), lo que significa que es un grupo masivo y de comportamiento sumamente predecible (muy cohesivo). Por el contrario, el cluster_1 presenta una dispersión enorme (-15,342,717), lo que en análisis de datos financieros indica la presencia de "valores atípicos" o compras extraordinariamente grandes que no siguen una regla estricta.

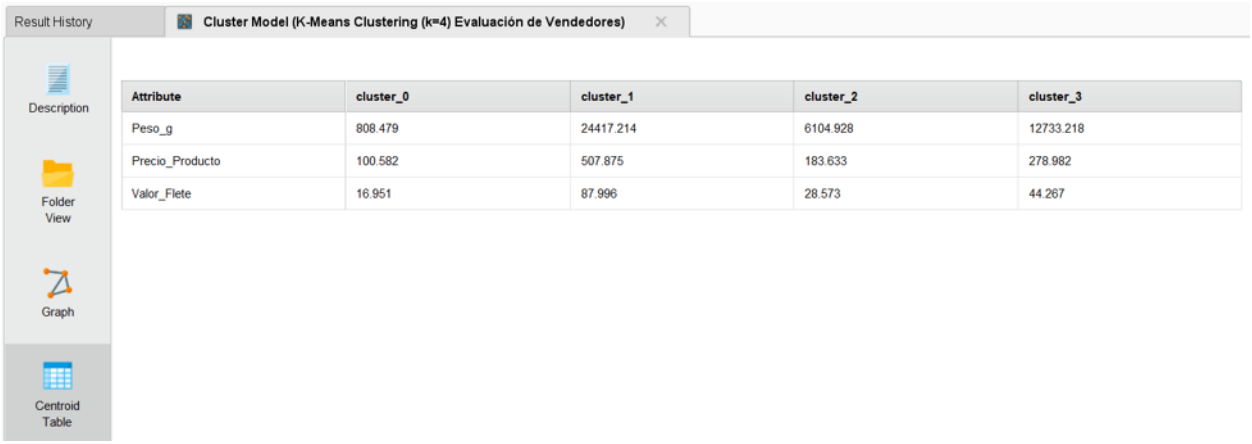
- **Interpretación Humana: ¿Qué significa esto para el negocio?** Al traducir la tabla de centroides a estrategia de ventas, descubrimos que Olist atiende a tres "Customer Personas" totalmente diferentes. Cada uno requiere estrategias de retención y marketing distintas:

1. **El Consumidor Cotidiano (Cluster 0 - Alta Densidad):** Este es el motor de volumen diario de Olist. Compran productos económicos (precio promedio $94.61), pagan un flete bajo ($18.93) y el valor total de su ticket es de apenas $140.93. Financian sus compras en menos de 3 cuotas (2.8 promedio).
    - *Acción Estratégica:* Aquí el margen de ganancia individual es bajo, por lo que el negocio depende del volumen. Olist debe aplicar estrategias de *Cross-selling* (ventas cruzadas) y envío gratis a partir de cierto monto para obligar a este cliente a subir su ticket promedio.
2. **El Comprador Aspiracional / Premium (Cluster 2 - Apalancamiento Máximo):** Este cliente compra productos costosos (precio promedio $691.31) y asume tickets totales que superan los $1,024. Sin embargo, su característica más importante es su dependencia del crédito: **utilizan casi 6 cuotas (5.8 promedio)** para poder pagar.
    - *Acción Estratégica:* Este segmento confirma el hallazgo de las Reglas de Asociación. Para el *Cluster 2*, la facilidad de pago es más importante que el precio final. Olist debe ofrecerles financiamiento extendido (ej. 9 o 12 meses) de forma agresiva para asegurar que no abandonen el carrito de compras.
3. **Las "Ballenas" o Clientes B2B (Cluster 1 - Ultra Alto Valor):** Este es un grupo atípico pero sumamente lucrativo. Registran compras exorbitantes con

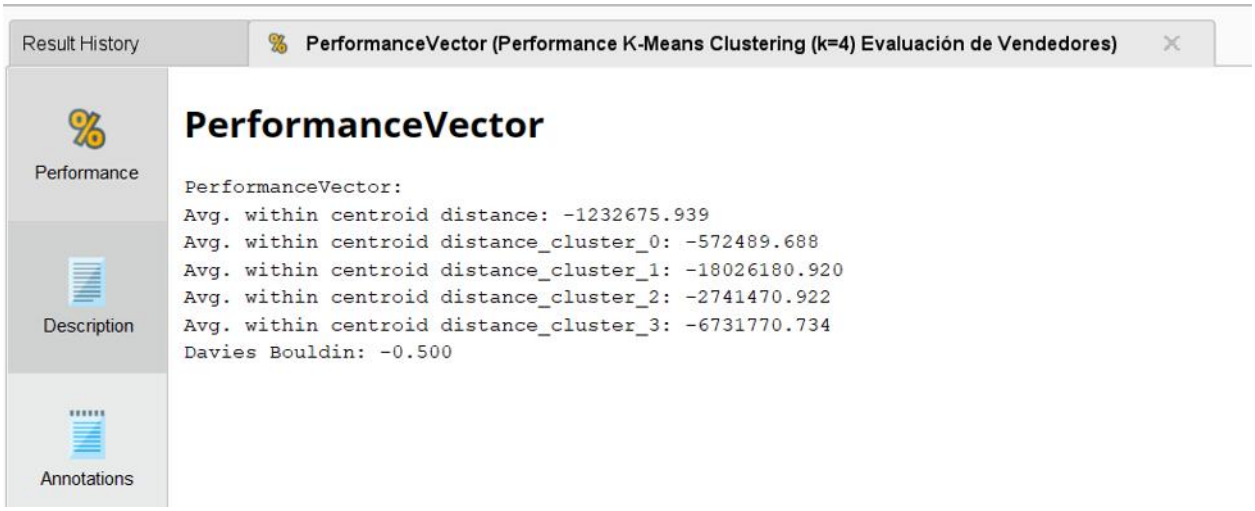
productos de $2,900 y tickets totales que rozan los **$6,898**. Lo más revelador es que, a pesar de gastar casi 7 veces más que el grupo Premium, usan muchas menos cuotas (solo 3.7). Esto indica alta liquidez; probablemente no son consumidores finales, sino pequeñas empresas (B2B) abasteciéndose a través de Olist.

- *Acción Estratégica:* A estos clientes no les interesan las cuotas, les interesa el servicio VIP. Olist debe crear un programa de "Ejecutivos de Cuenta" para atender a este clúster, ofreciéndoles facturación empresarial, soporte prioritario y seguros de envío, ya que su retención inyecta capital masivo a la plataforma.

3.6 Evaluación del Modelo 5 de Clustering: Segmentación de Vendedores y Logística (K-Means, k=4)



Attribute	cluster_0	cluster_1	cluster_2	cluster_3
Peso_g	808.479	24417.214	6104.928	12733.218
Precio_Producto	100.582	507.875	183.633	278.982
Valor_Flete	16.951	87.996	28.573	44.267



Para optimizar la relación B2B (Business-to-Business) entre la plataforma y sus vendedores, se implementó un modelo de K-Means con 4 clústeres. El objetivo fue perfilar a los "Sellers" de Olist basándonos exclusivamente en la huella logística de su inventario: qué tan pesados son sus productos (Peso_g), qué precio tienen (Precio_Producto) y cuánto cuesta moverlos (Valor_Flete).

- **Evaluación Matemática del Modelo (Cohesión y Separación)** El agrupamiento en 4 perfiles arrojó resultados estadísticos muy consistentes:
    1. **Índice Davies-Bouldin (-0.500):** Un valor exacto de -0.500 demuestra una clara separación matemática entre los grupos. Los vendedores no son una masa homogénea; operan en nichos con exigencias físicas y financieras muy distintas.
    2. **Análisis de Dispersión (Distancia Intra-clúster):** El evaluador revela que el cluster_0 es el grupo más compacto y predecible (distancia de -572,489). Esto significa que la inmensa mayoría de los vendedores operan bajo un estándar muy rígido. En contraste, el cluster_1 presenta una dispersión enorme (-18,026,180), indicando que los vendedores de este grupo manejan catálogos muy atípicos, con productos de pesos y dimensiones altamente variables.
- **Interpretación Humana: ¿Qué significa esto para el negocio?** La tabla de centroides nos permite clasificar a los vendedores de Olist en 4 arquetipos operativos. Entender esto es vital para asignarles el proveedor de paquetería correcto y evitar los retrasos que descubrimos en los modelos anteriores:
    1. **El "Retailer" de Alto Volumen (Cluster 0):** Este es el vendedor estándar de comercio electrónico. Vende productos muy ligeros (peso promedio de apenas 808 gramos), económicos (precio de $100.58) y con un flete barato ($16.95).
        - *Impacto Estratégico:* Este grupo genera el volumen masivo de la plataforma (accesorios, fundas, cosméticos). Para ellos, Olist debe ofrecer procesos de impresión de etiquetas automatizados y convenios con servicios de mensajería rápida en motocicletas o furgonetas pequeñas.
    2. **El Distribuidor de Carga Pesada (Cluster 1):** En el extremo opuesto, tenemos a los vendedores de productos industriales, muebles o

electrodomésticos. Mueven cargas pesadísimas (promedio de **24.4 kg / 24,417 g**), con un alto valor ($507.87) y el flete más caro de la red ($87.99).

- *Impacto Estratégico:* **Este es el clúster de mayor riesgo.** Si recordamos el Árbol de Decisión (Modelo 1), la carga pesada con fletes altos es la principal causante de entregas tardías en estados complejos como Río de Janeiro. Olist no puede permitir que estos vendedores usen paqueterías estándar; debe obligarlos a operar con flotillas especializadas en carga pesada (LTL - *Less than Truckload*).

3. **Los Vendedores de Rango Medio (Clusters 2 y 3):** Estos dos grupos representan la transición entre lo ligero y lo pesado:
   - **Cluster 2:** Productos medianos de **6.1 kg** (ej. pequeños electrodomésticos, decoración) con un precio de $183.63.
   - **Cluster 3:** Productos medianos-pesados de **12.7 kg** (ej. equipos deportivos, muebles desarmables) con un precio de $278.98 y fletes de $44.26.
   - *Impacto Estratégico:* Estos vendedores están en una zona gris donde un mal embalaje puede disparar sus costos de envío. Olist debería ofrecerles consultoría o subsidios en materiales de empaque para optimizar el peso volumétrico y evitar que el cliente final abandone la compra por un flete demasiado alto.

XI. BIBLIOGRAFÍA

Olist Store. (s.f.). Brazilian E-Commerce Public Dataset by Olist [Conjunto de datos]. Kaggle. Obtenido de https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce

Universidad Don Bosco. (2020). Guía de laboratorio Nº 9 [Archivo PDF]. https://www.udb.edu.sv/udb_files/recursos_guias/informatica-ingenieria/datawarehouse-y-mineria-de-datos/2020/ii/guia-9.pdf

Universidad Don Bosco. (2020). Guía de laboratorio Nº 10: Minería de datos – Agrupamiento con K-means [Archivo PDF]. https://www.udb.edu.sv/udb_files/recursos_guias/informatica-ingenieria/datawarehouse-y-mineria-de-datos/2020/ii/guia-10.pdf

Universidad Don Bosco. (2020). Guía de laboratorio Nº 11: Árbol de decisión [Archivo PDF]. https://www.udb.edu.sv/udb_files/recursos_guias/informatica-ingenieria/datawarehouse-y-mineria-de-datos/2020/ii/guia-11.pdf